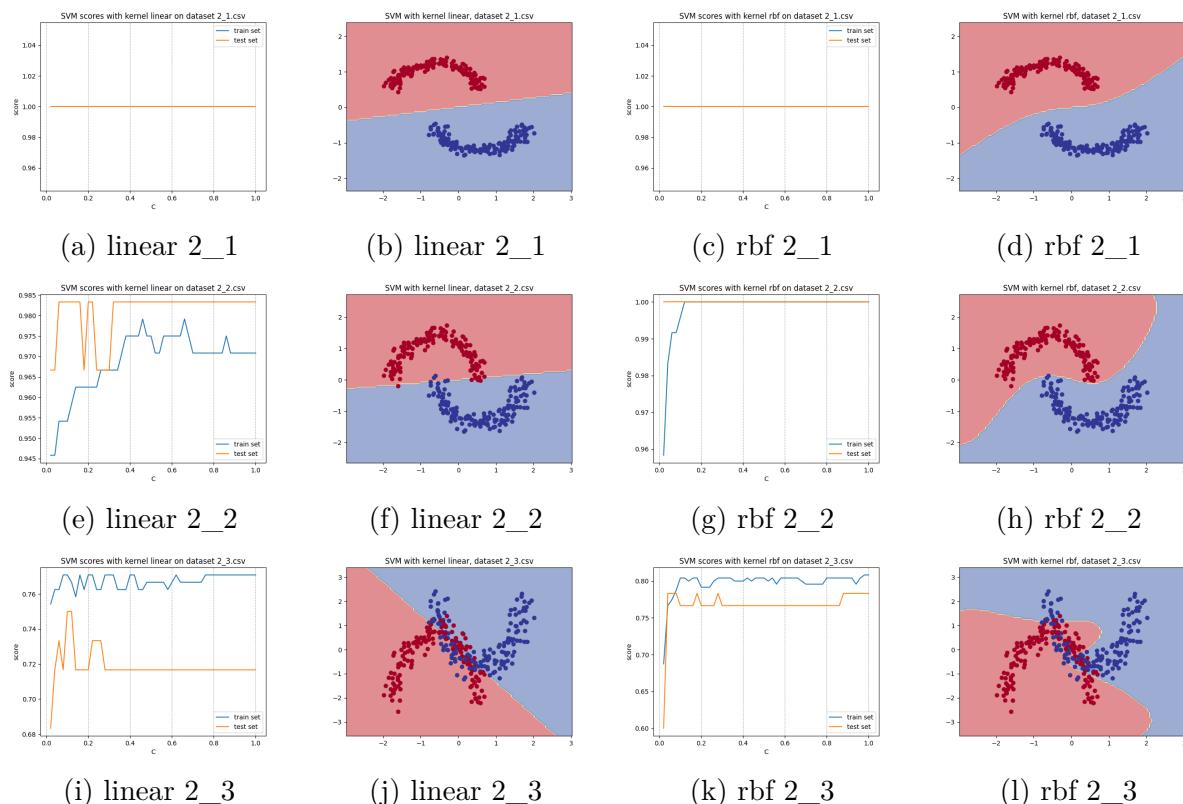
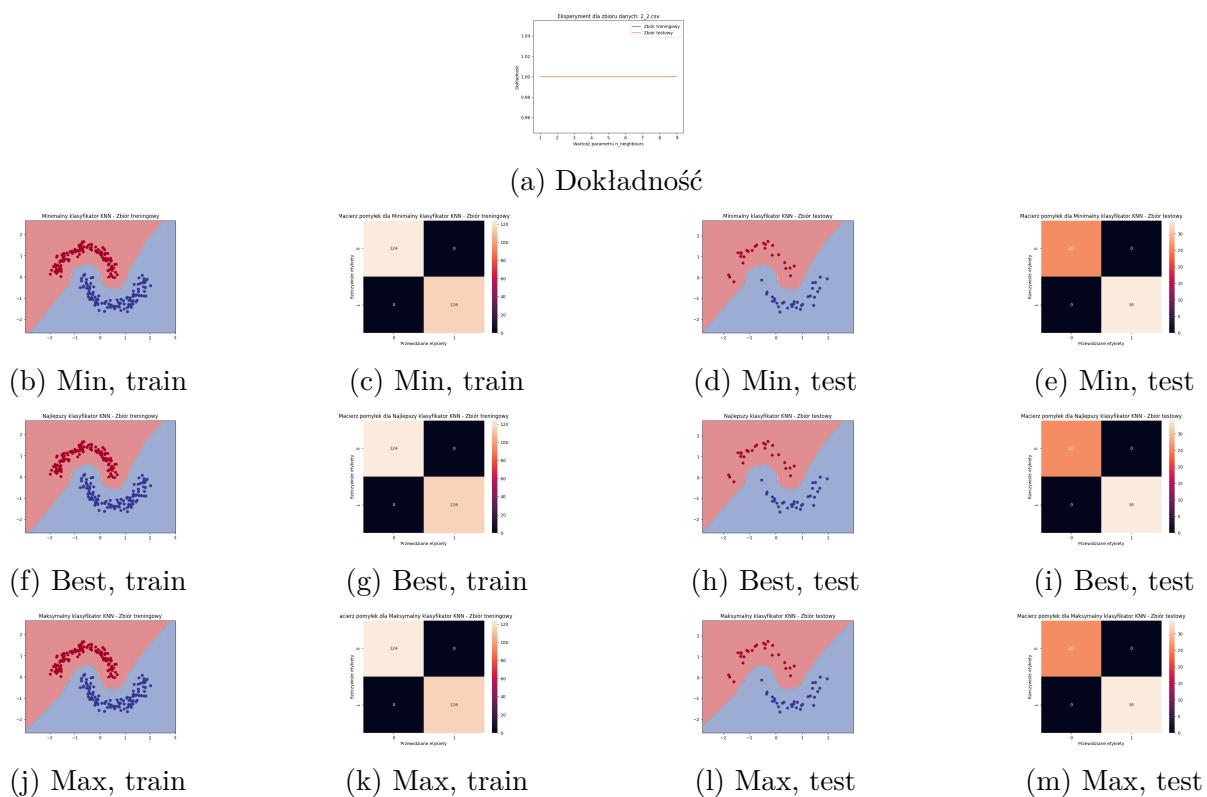


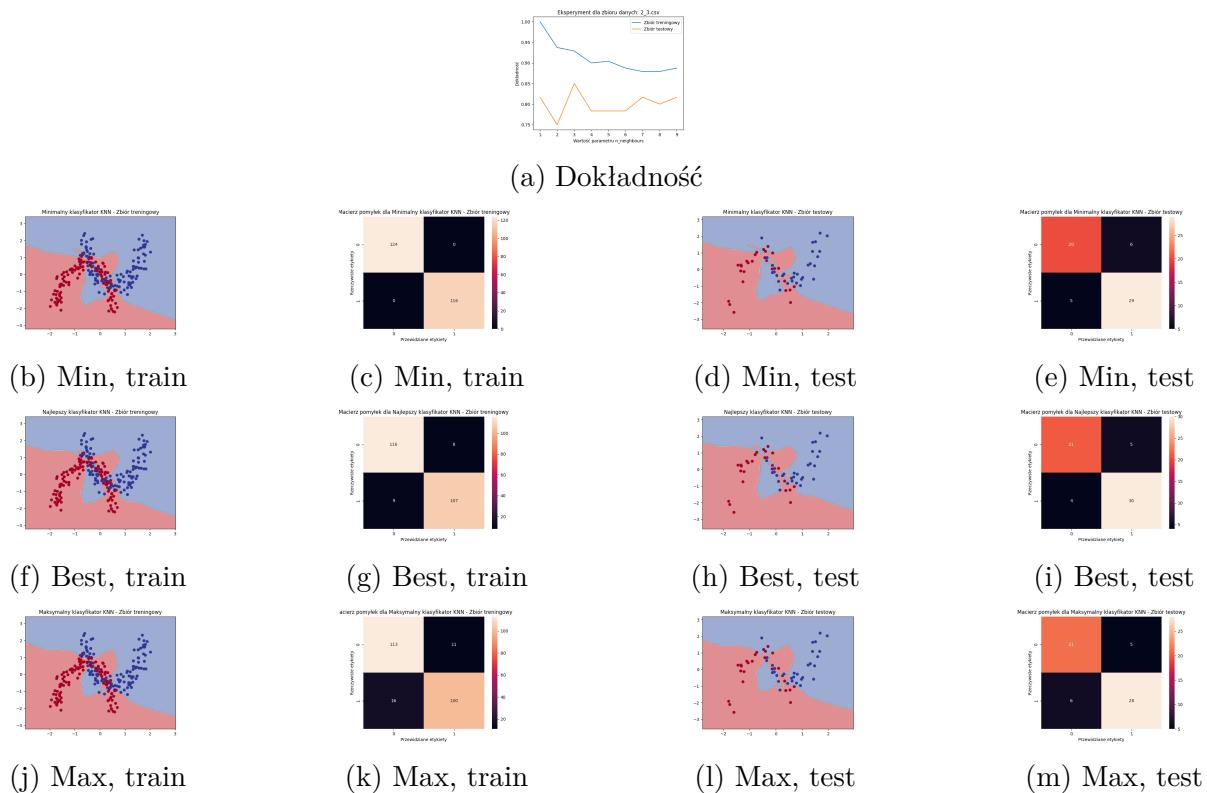
Rysunek 1: Eksperyment 1 — Perceptron MLP



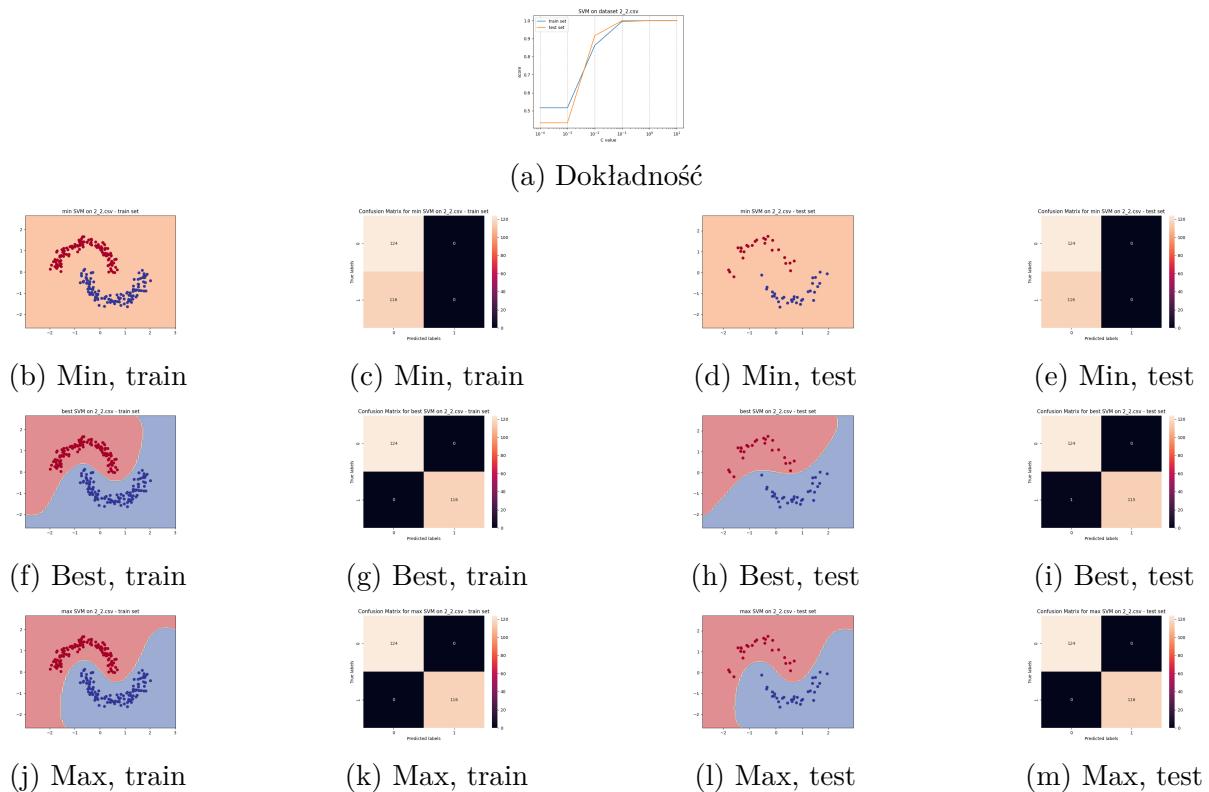
Rysunek 2: Eksperyment 1 — SVM



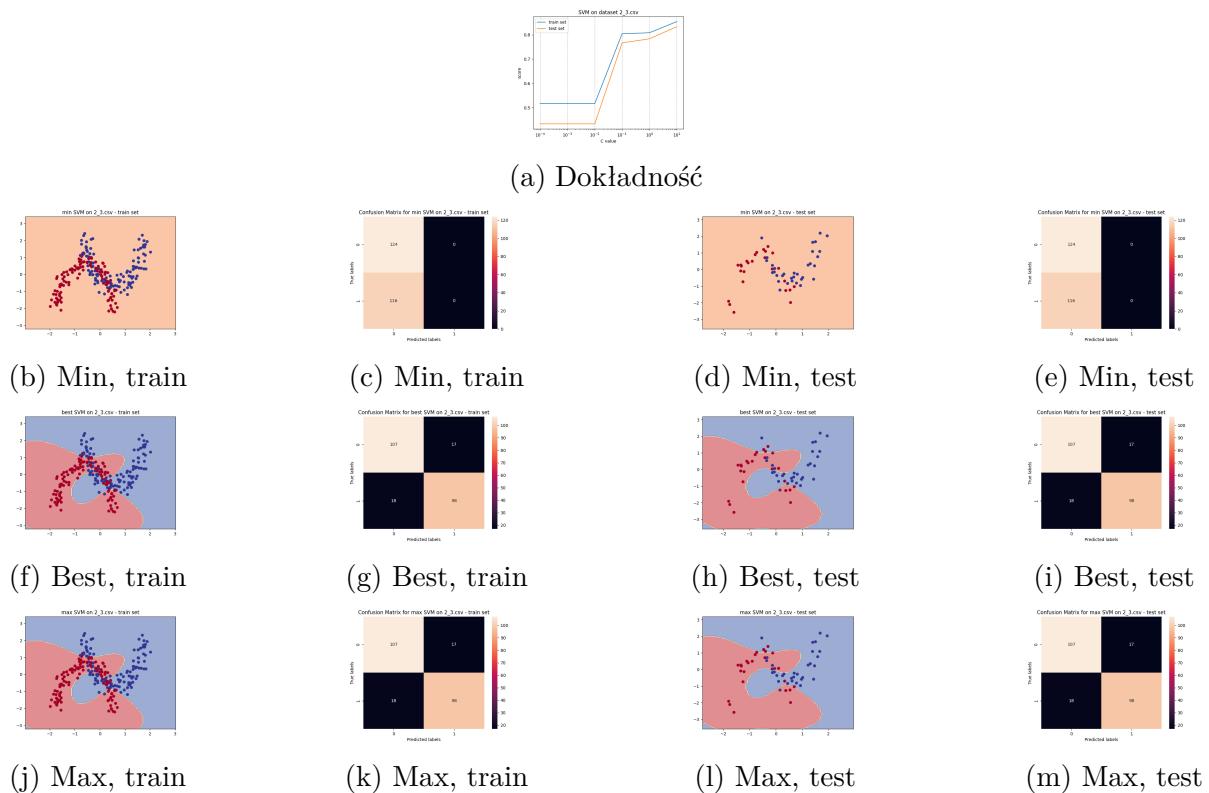
Rysunek 3: Eksperyment 2 — KNN na zbiorze 2\_2



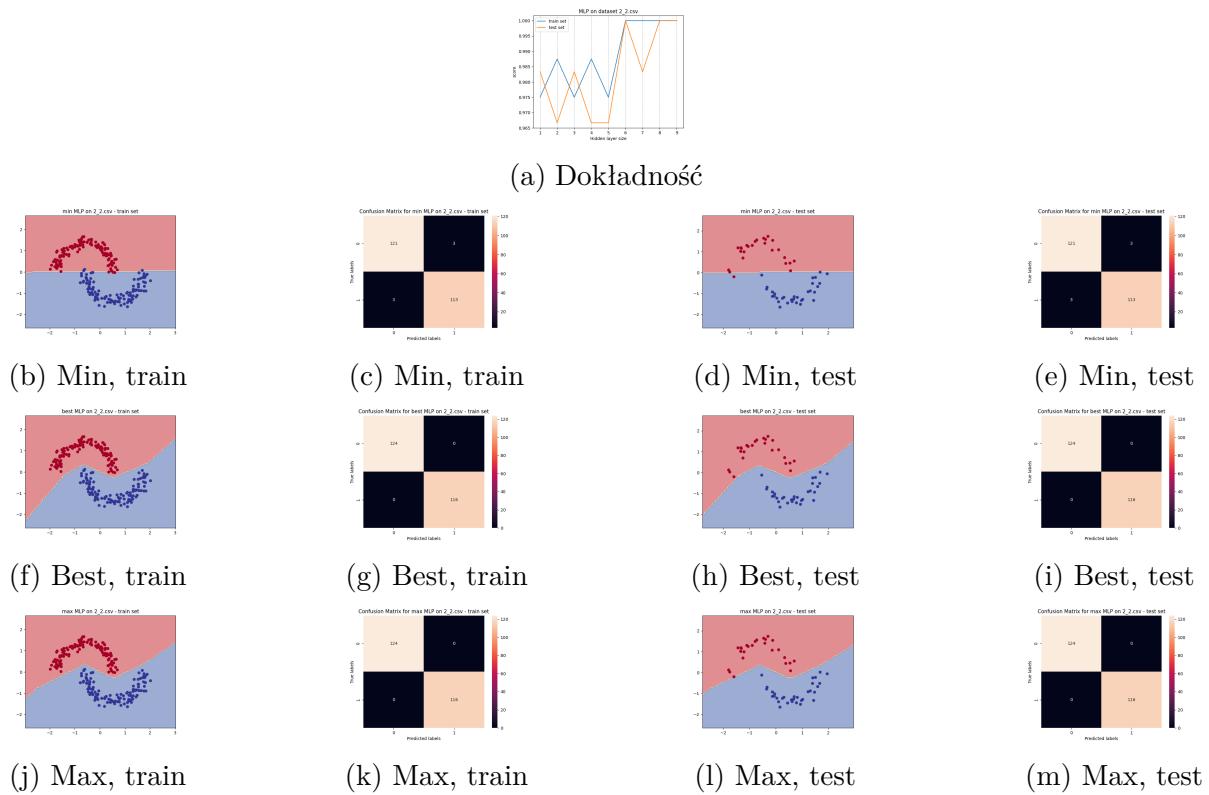
Rysunek 4: Eksperyment 2 — KNN na zbiorze 2\_3



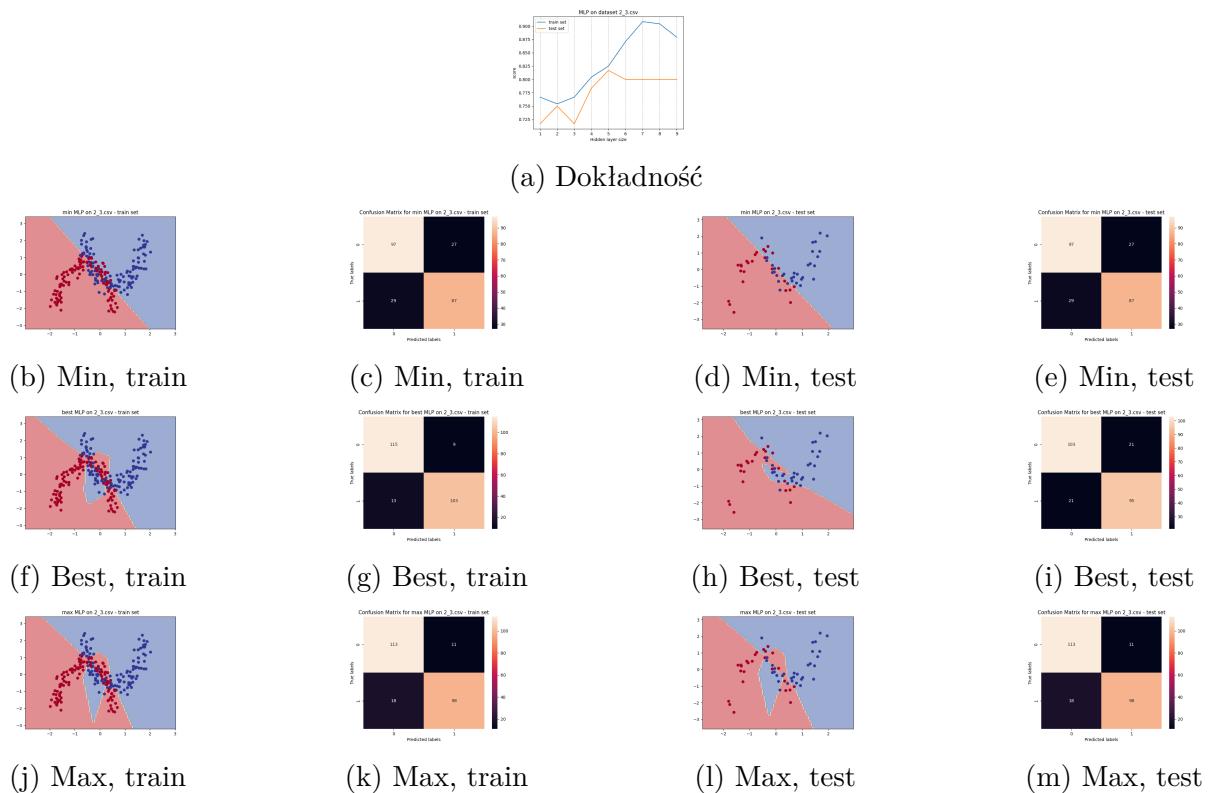
Rysunek 5: Eksperyment 2 — SVM na zbiorze 2\_2



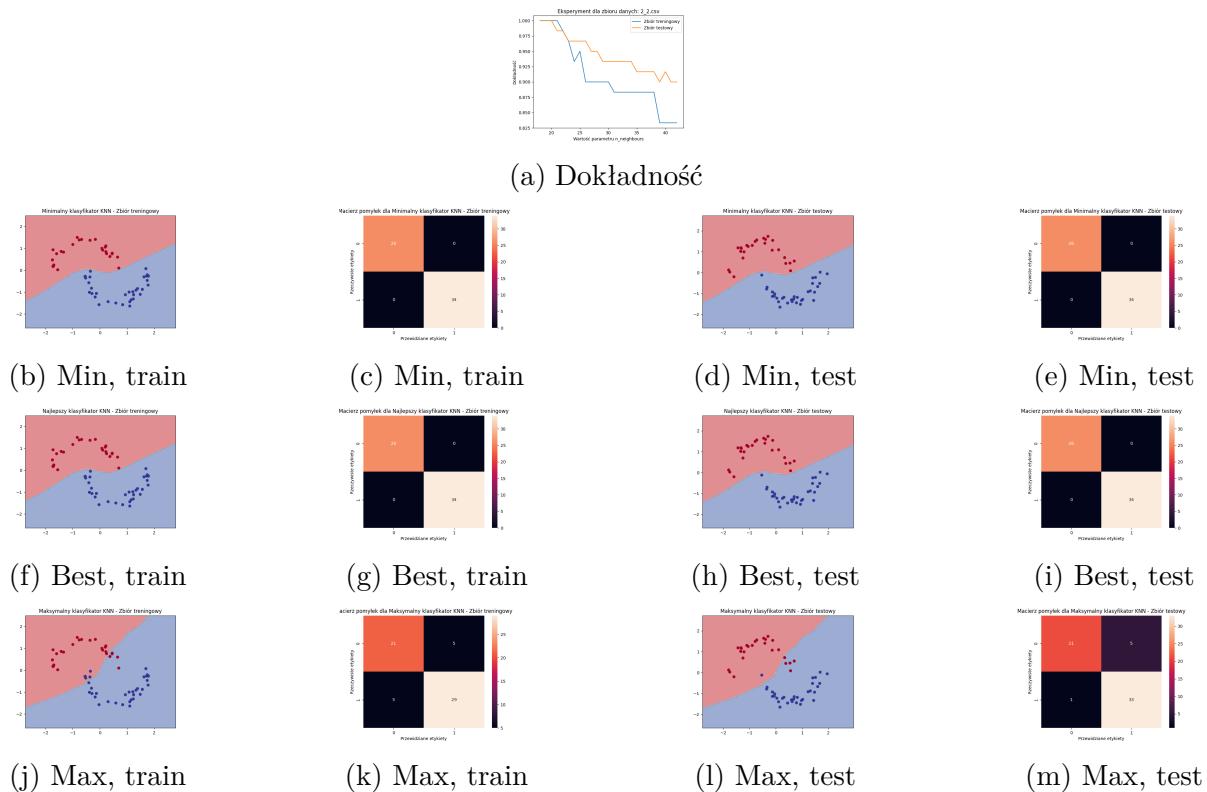
Rysunek 6: Eksperyment 2 — SVM na zbiorze 2\_3



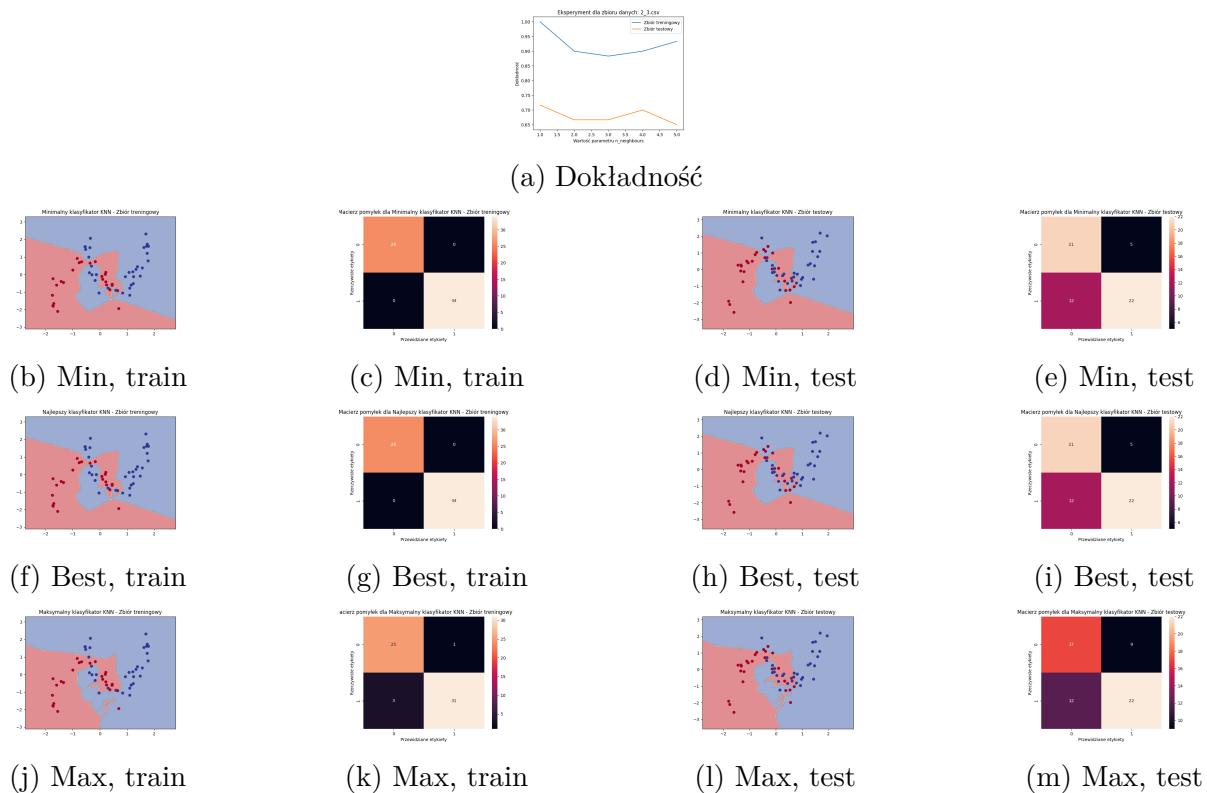
Rysunek 7: Eksperyment 2 — MLP na zbiorze 2\_2



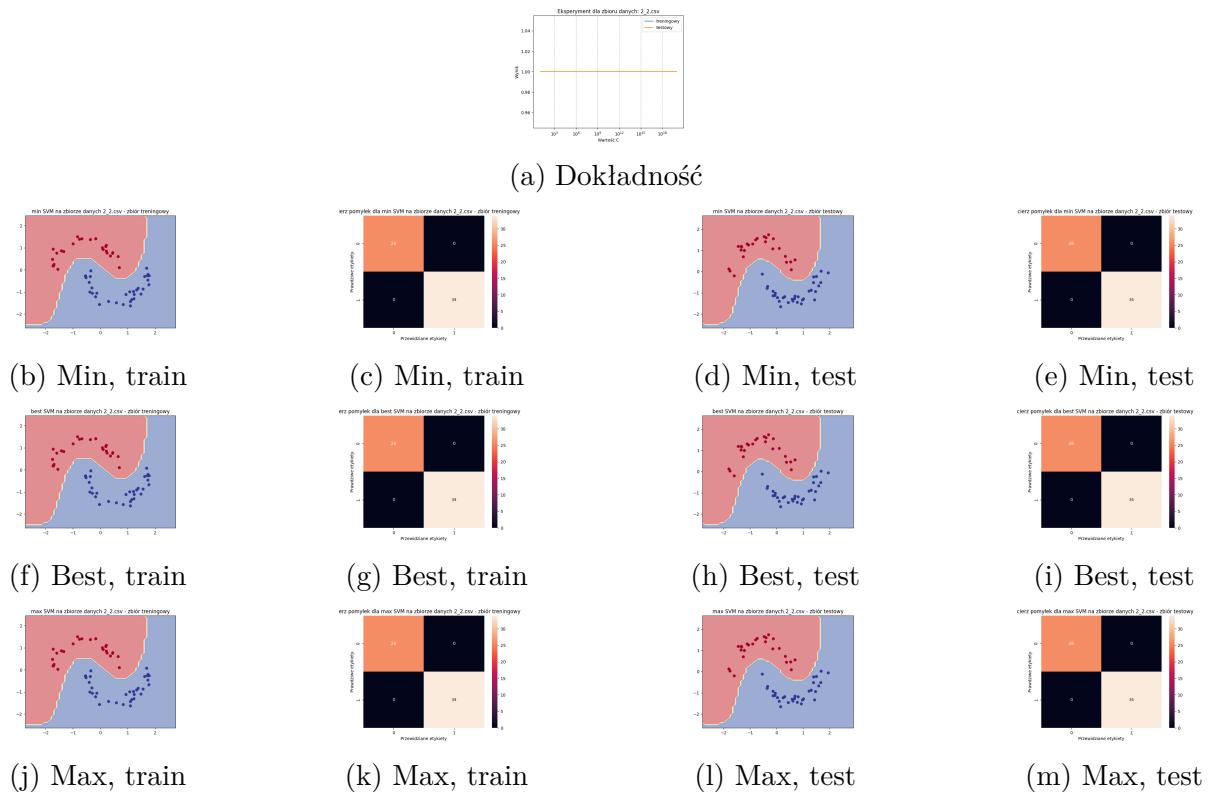
Rysunek 8: Eksperyment 2 — MLP na zbiorze 2\_3



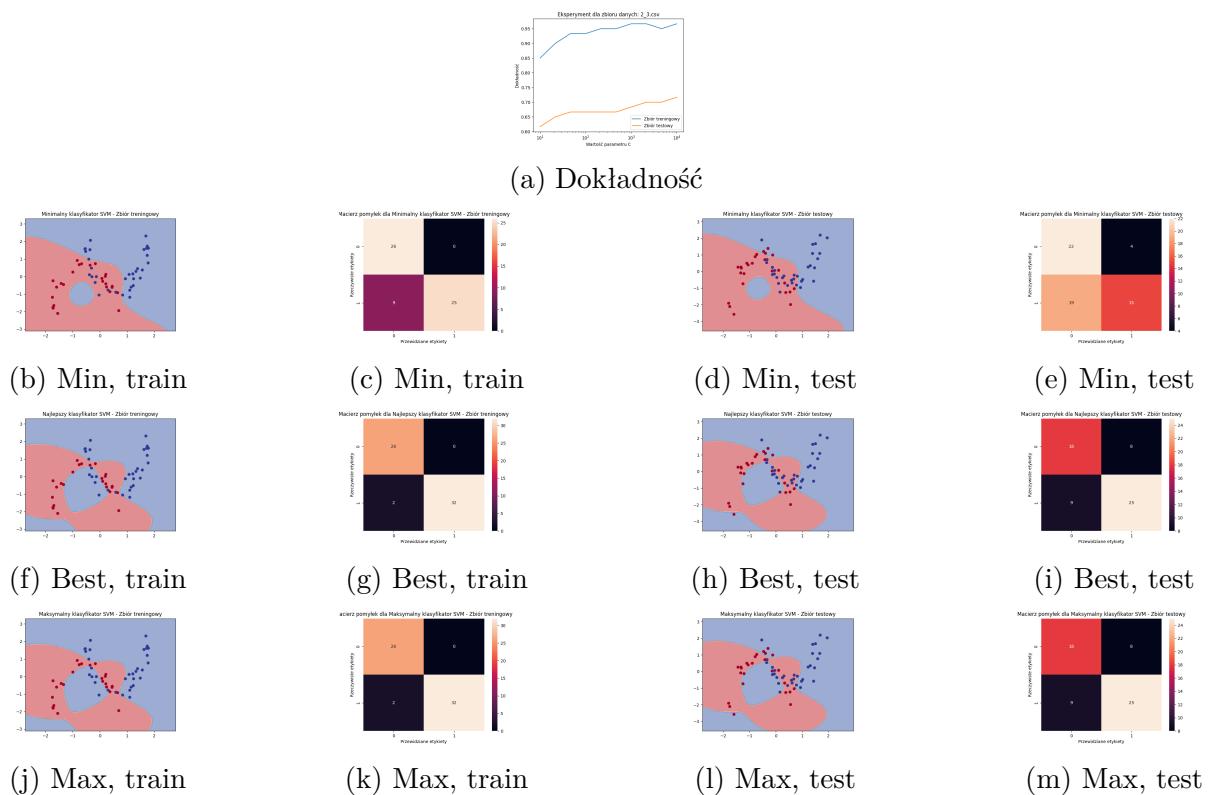
Rysunek 9: Eksperyment 3 — KNN na zbiorze 2\_2



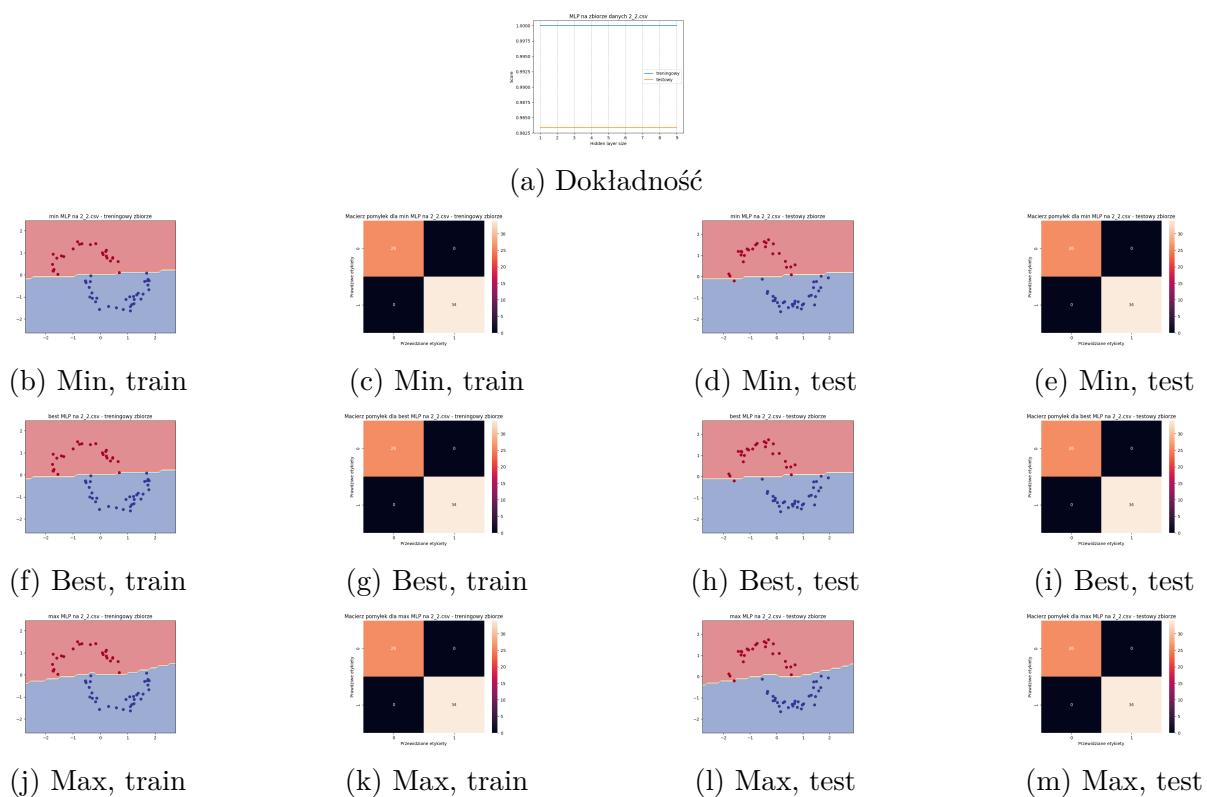
Rysunek 10: Eksperyment 3 — KNN na zbiorze 2\_3



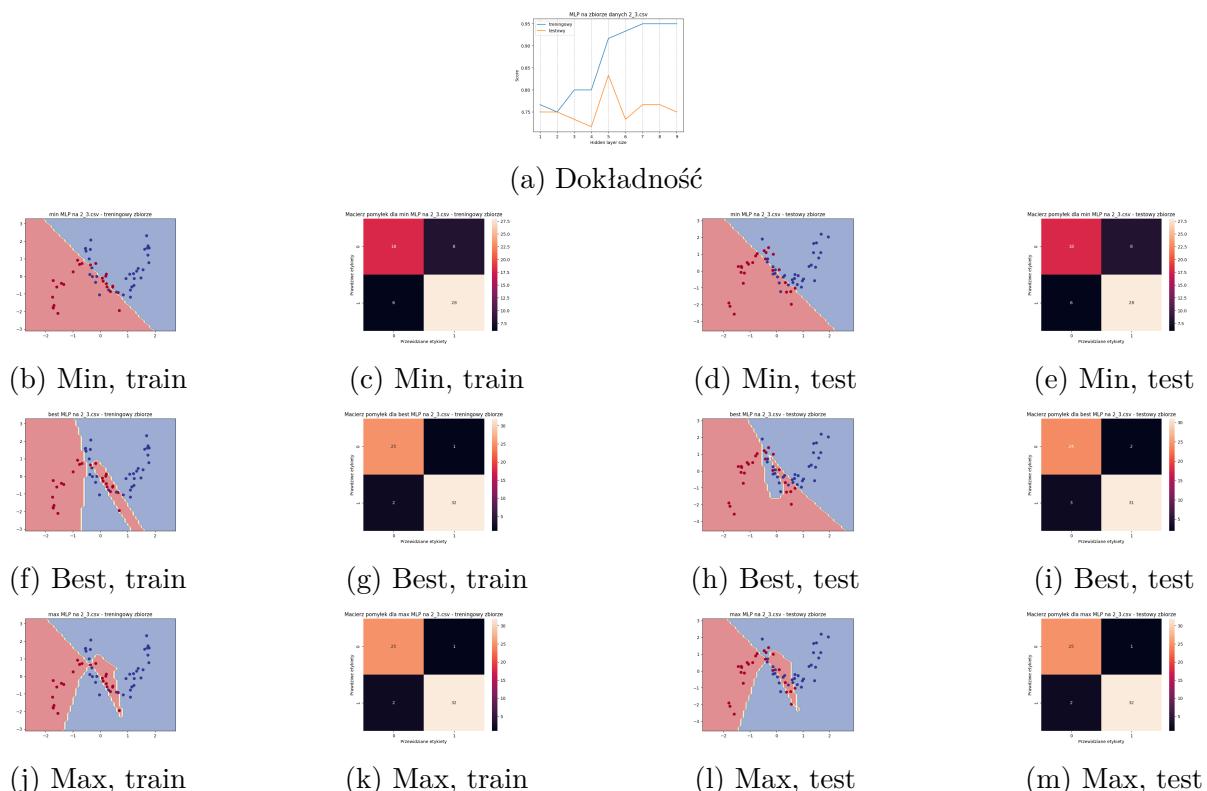
Rysunek 11: Eksperyment 3 — SVM na zbiorze 2\_2



Rysunek 12: Eksperyment 3 — SVM na zbiorze 2\_3



Rysunek 13: Eksperyment 3 — MLP na zbiorze 2\_2



Rysunek 14: Eksperyment 3 — MLP na zbiorze 2\_3

8 strona — Wyniki czwartego eksperymentu dla sztucznie wygenerowanego zbioru danych 2\_3 oraz sieci MLP. Dla rozważanego zbioru należy rozważyć przypadki z różną liczbą danych treningowych (parametr train\_size równy równy wartościom użytym odpowiednio w eksperymetach drugim i trzecim). Dla obu przypadków należy zaprezentować wykres zmian accuracy na zbiorach treningowym i testowym w kolejnych epokach oraz wizualizacje przebiegu granicy decyzyjnej na zbiorach treningowym i testowym dla epoki: zerowej (przed rozpoczęciem nauki), najlepszej (wartość accuracy na zbiorze testowym) i ostatniej (po zakończeniu nauki). Dodatkowo w każdym z przypadków należy uruchomić proces treningu 10 razy z różnymi wagami początkowymi i w tabeli zamieścić wartości accuracy na zbiorze testowym i treningowym dla epoki: pierwszej (początek nauki), najlepszej (wartość accuracy na zbiorze testowym) i ostatniej (po zakończeniu nauki). W przypadku wartości najlepszej należy również podać numer epoki kiedy ją osiągnięto. Liczbę neuronów w warstwie ukrytej należy dobrą jako tą optymalną wynikającą odpowiednio z eksperymetów drugiego i trzeciego.

9 strona — Opis wniosków z eksperymentów przeprowadzonych na sztucznie wygenerowanych zbiorach. W przypadku wszystkich eksperymentów należy zwrócić uwagę na kształt uzyskiwanych granic decyzyjnych i związane z nim zdolności uogólniające poszczególnych rodzajów klasyfikatorów (wpływ hiperparametrów) oraz wpływ liczby danych treningowych. W eksperymencie czwartym należy dodatkowo skupić się na zdolnościach uogólniających w kolejnych epokach nauki oraz na wpływie sposobu zainicjalizowania sieci. Wnioski powinny mieć charakter ogólny, pozwalający przenieść je na przypadek, w którym nie ma możliwości zwizualizowania danych. Każdy wniosek powinien być poparty odniesieniami do wyników przedstawionych na pierwszych czterech stronach raportu.

## Eksperiment 1

Z eksperymentów na wygenerowanych danych można wyciągnąć wnioski dotyczące elastyczności rozważanych klasyfikatorów oraz wpływu ich hiperparametrów na kształt granic decyzyjnych. W przypadku klasyfikatora SVM istotnym parametrem jest kernel, który definiuje kształt granicy decyzyjnej. Porównując różne kernele, takie jak linear i rbf, można zauważać różnice w elastyczności modelu. Podobnie, dla klasyfikatora opartego o sieć MLP, parametr activation wpływa na kształt granicy decyzyjnej, dlatego porównanie różnych funkcji aktywacji, takich jak identity i relu, jest istotne dla oceny elastyczności modelu.

## Eksperiment 2

Drugi eksperiment koncentruje się na wpływie elastyczności modelu na jego zdolności generalizacyjne. Zmiana hiperparametrów, takich jak liczba sąsiadów dla klasyfikatora K-NN, parametr C dla klasyfikatora SVM oraz liczba neuronów w warstwie ukrytej dla sieci MLP, ma istotny wpływ na zdolności generalizacyjne modelu. Badanie tego wpływu na podziale danych na zbiór treningowy i testowy pozwala ocenić skuteczność klasyfikacji na nowych, nie widzianych wcześniej danych, co można zaobserować na przeprowadzonych testach.

## Eksperiment 3

Trzeci eksperiment rozważa wpływ zmiany hiperparametrów modelu na jego zdolności generalizacyjne w przypadku niewielkiej liczby danych treningowych równej 0.2. Przy ograniczonym zbiorze treningowym istotne staje się dobranie optymalnych hiperparametrów, aby uniknąć przeuczenia, co można zaobserwować na zmianie wykresu accuracy, gdzie w przypadku zbioru 2\_2 przez pierwsze 30 ukrytych warstw nie ma zmiany, a w przypadku 2\_3 ma to ogromne znaczenie, dlatego przedstawiono tylko pierwsze warstwy. Wynika to ze specyfikacji danego zbioru. Porównanie różnych kombinacji hiperparametrów pozwala zidentyfikować te, które prowadzą do najlepszych wyników przy ograniczonej liczbie danych.

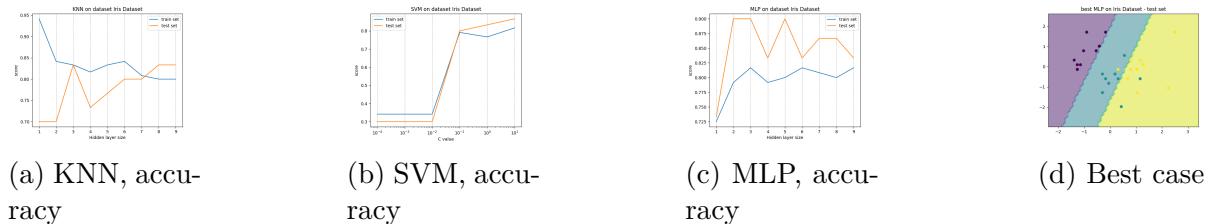
## Eksperiment 4

Czwarty eksperiment skupia się na obserwacji procesu nauki sieci MLP. Dzięki wykorzystaniu metody `partial_fit` można śledzić zmiany skuteczności modelu na zbiorze treningowym i testowym po kolejnych epokach nauki. Dodatkowo, badając wpływ różnych inicjalizacji wag neuronów na finalne rezultaty klasyfikacji, można lepiej zrozumieć proces uczenia się sieci i jego wpływ na zdolności generalizacyjne modelu.

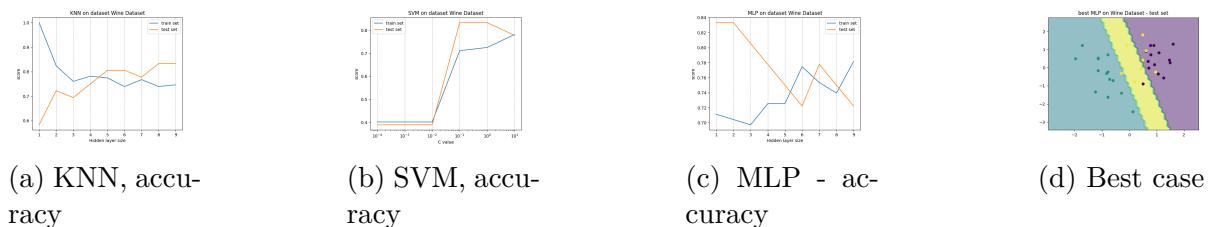
10 strona — Opis działania analizowanych metod klasyfikacji w przypadku rzeczywistych zbiorów danych. Podczas tworzenia klasyfikatorów warto skorzystać z wniosków wyciągniętych podczas wcześniejszych eksperymentów. Uzyskane wyniki należy zaprezentować w zwartej formie (warto wykorzystać tabele i/lub wykresy), a wnioski należy poprzedzić odwołaniami do tych wyników.

Rysunki 15 - 17 przedstawiają wyniki eksperymentów z użyciem KNN, SVM i MLP na zbiorach Iris, Wine oraz Breast Cancer Wisconsin W przypadku metody K-NN skoncentrowaliśmy się na optymalnej liczbie sąsiadów  $n_{neighbours}$ . Dla metody SVM dobraliśmy optymalną wartość parametru C, kontrolującego tolerancję naruszenia marginesu. Natomiast dla sieci MLP ustaliliśmy optymalną liczbę neuronów w warstwie ukrytej.

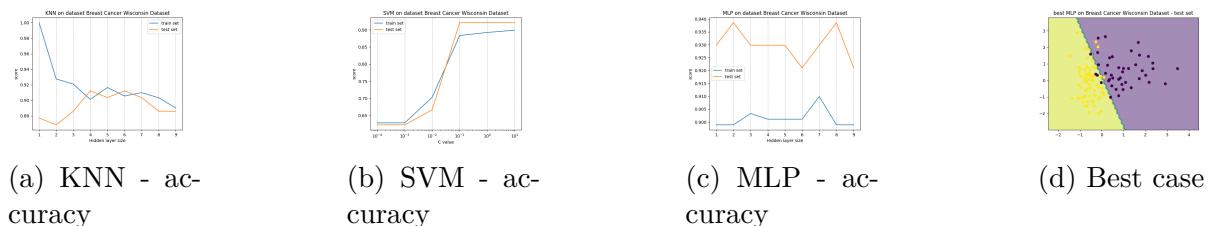
Wyniki działania klasyfikatorów na rzeczywistych danych zostały przedstawione w formie tabel oraz wykresów. Dokładnie przeanalizowaliśmy skuteczność klasyfikacji na zbiorze treningowym i testowym, a także zbadaliśmy macierz pomyłek dla każdej z metod. Nasza analiza wskazuje, że wybrane metody klasyfikacji dobrze radzą sobie z rzeczywistymi danymi. Klasyfikatory osiągają zadowalające wyniki zarówno na zbiorach treningowych, jak i testowych



Rysunek 15: Wyniki eksperymentów na zbiorze Iris



Rysunek 16: Wyniki eksperymentów na zbiorze Wine



Rysunek 17: Wyniki eksperymentów na zbiorze Breast Cancer Wisconsin