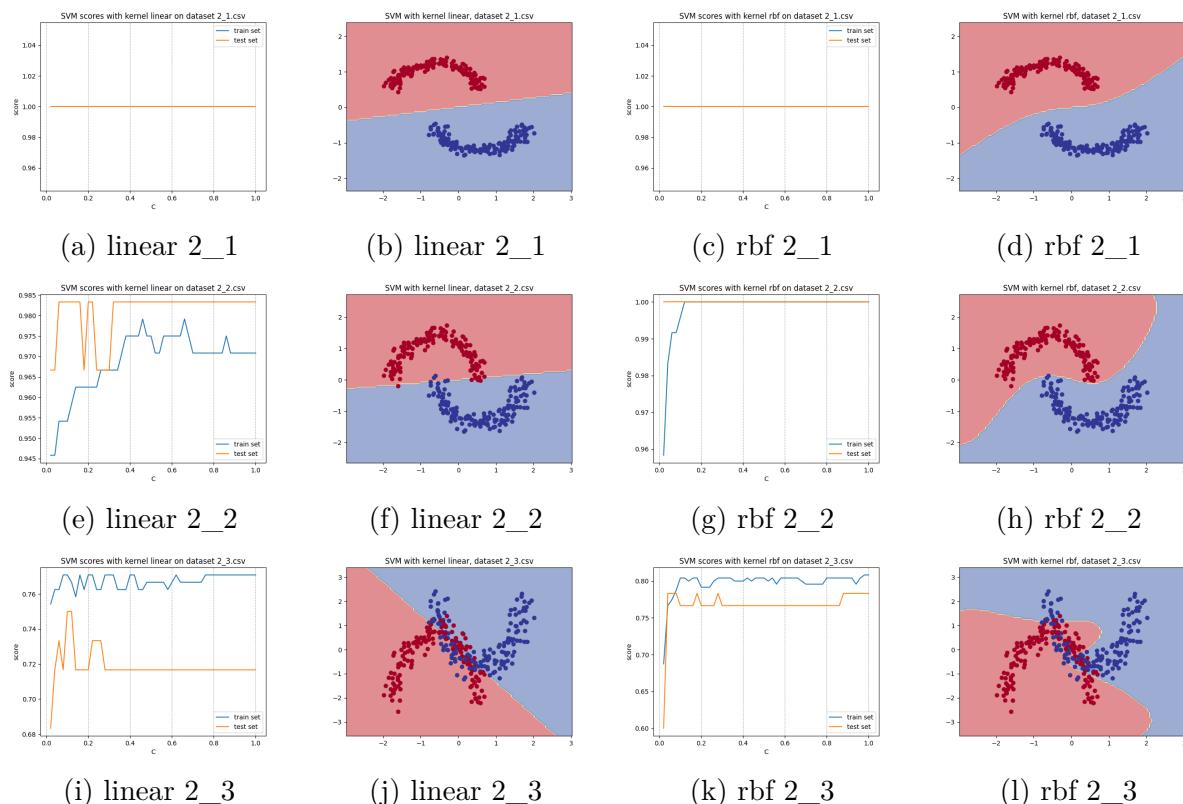
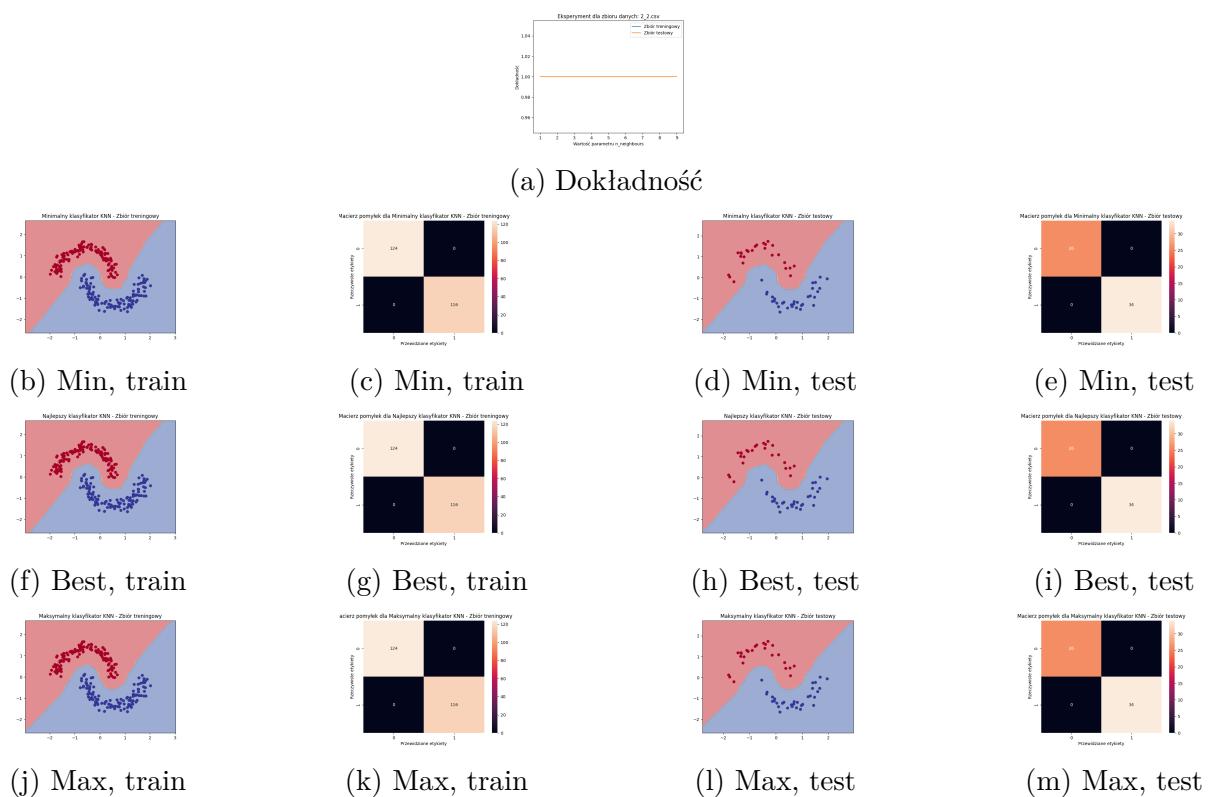


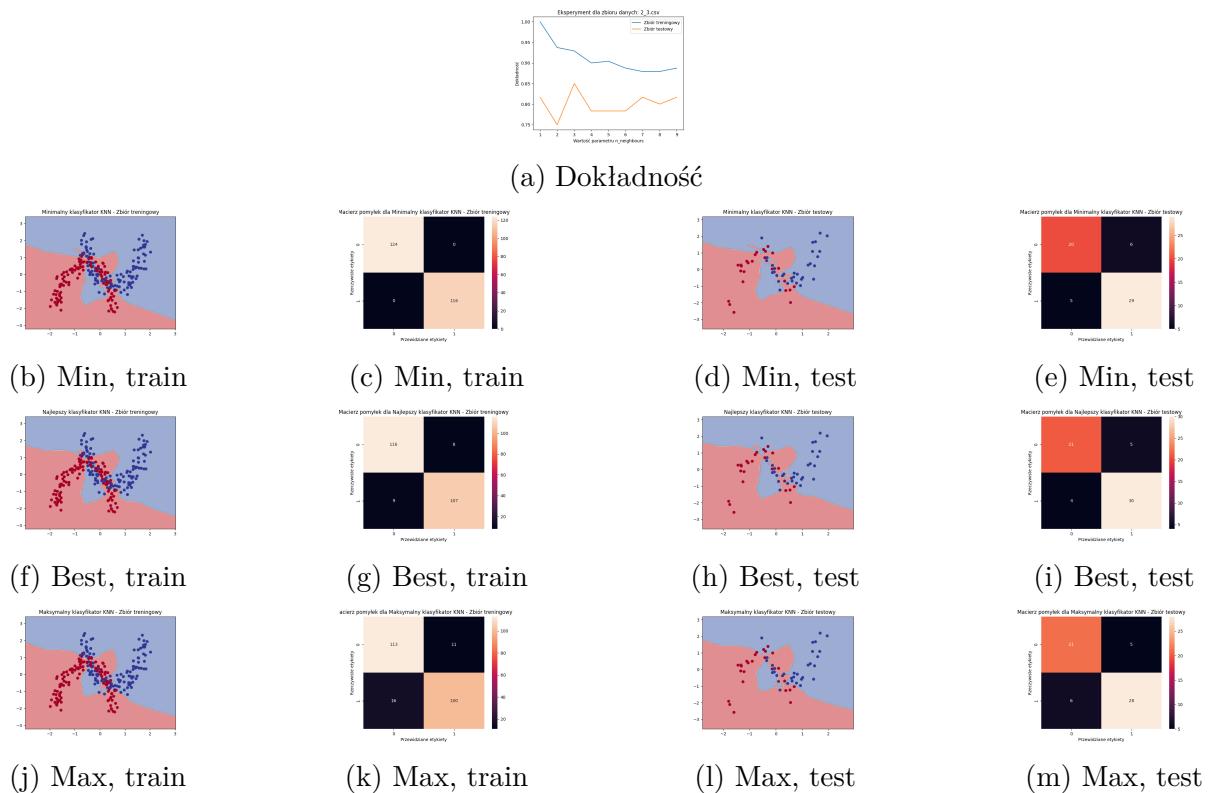
Rysunek 1: Eksperyment 1 — Perceptron MLP



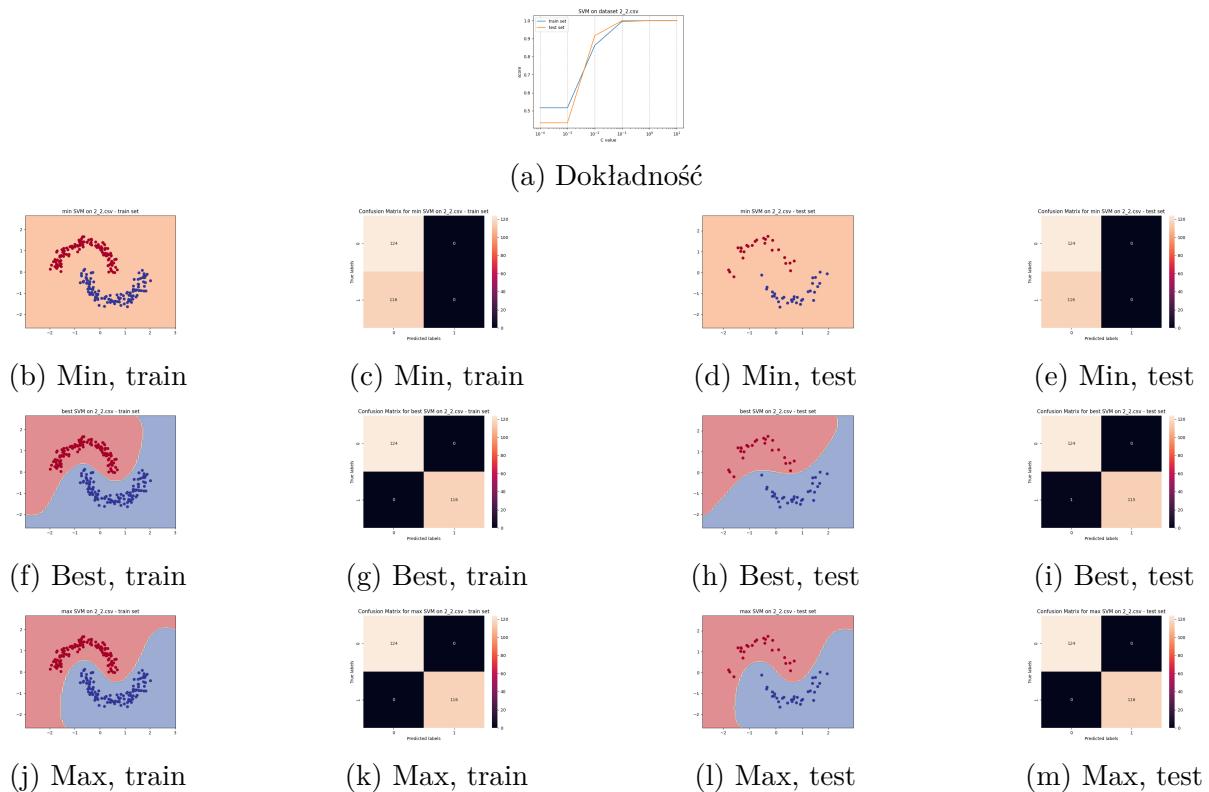
Rysunek 2: Eksperyment 1 — SVM



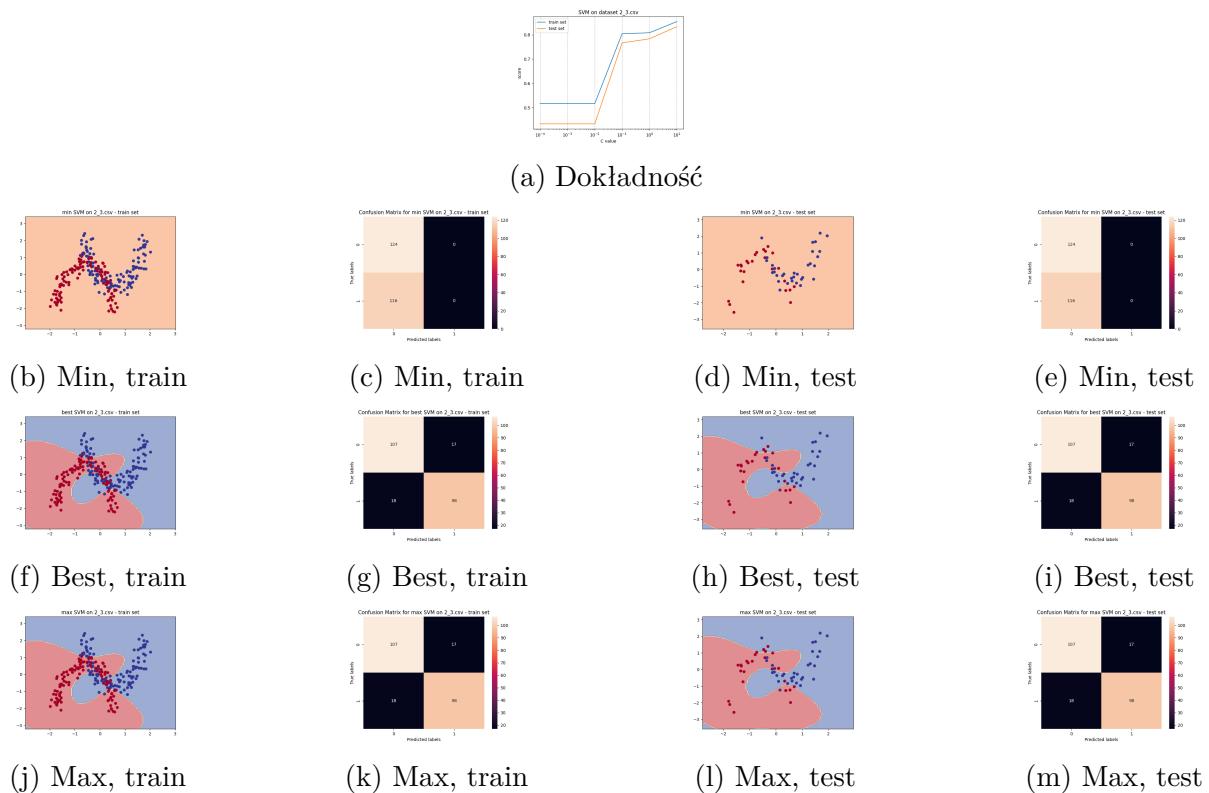
Rysunek 3: Eksperyment 2 — KNN na zbiorze 2\_2



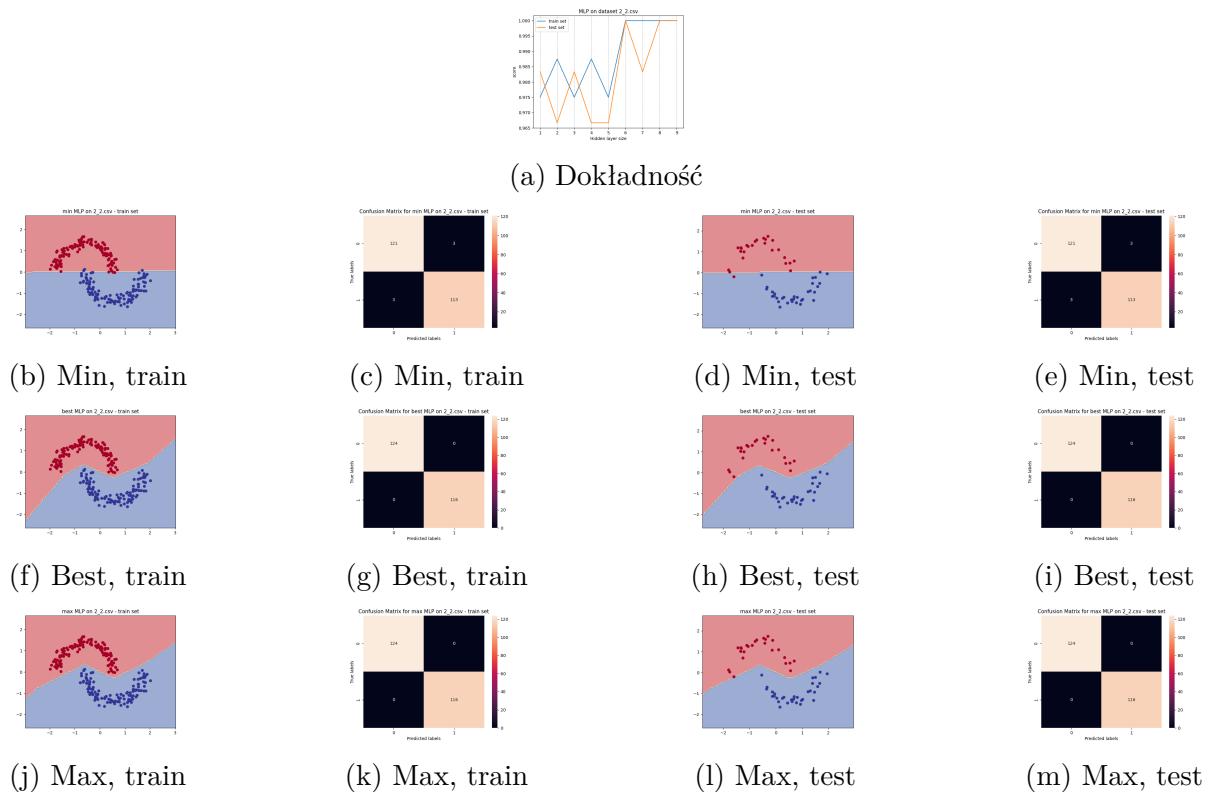
Rysunek 4: Eksperyment 2 — KNN na zbiorze 2\_3



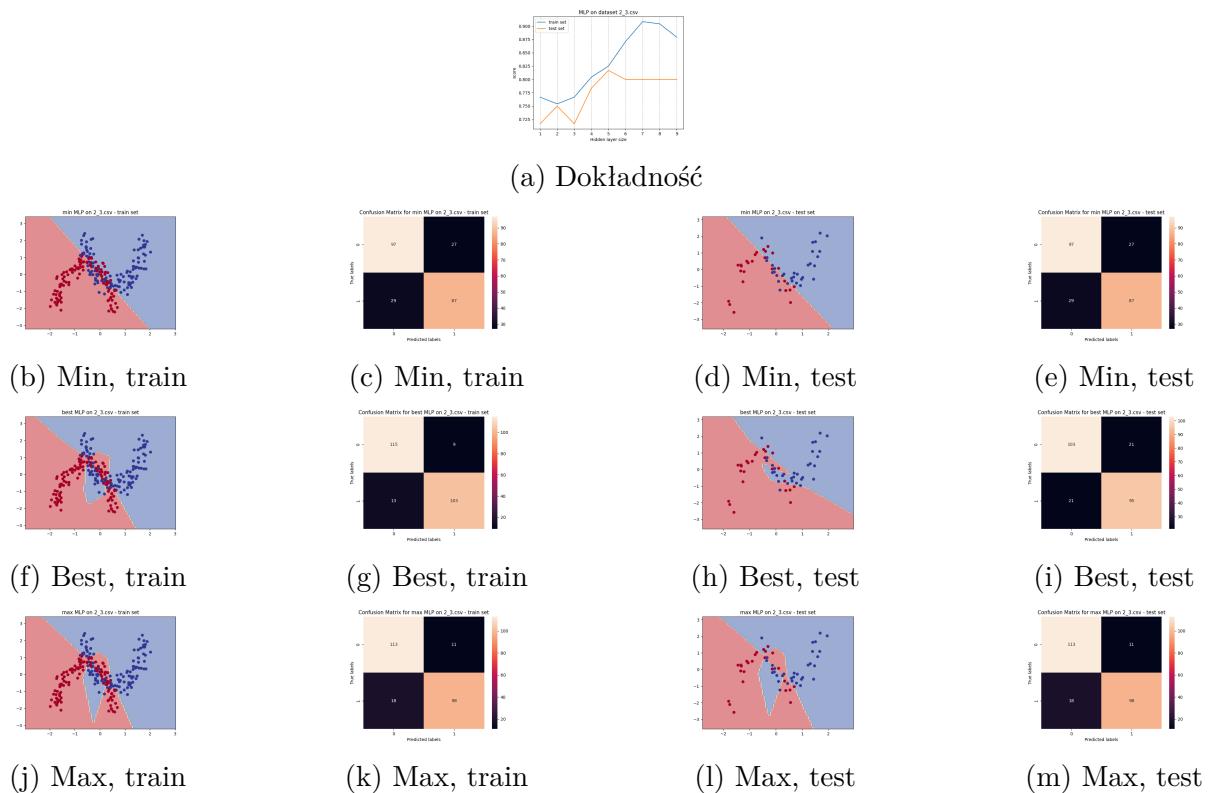
Rysunek 5: Eksperyment 2 — SVM na zbiorze 2\_2



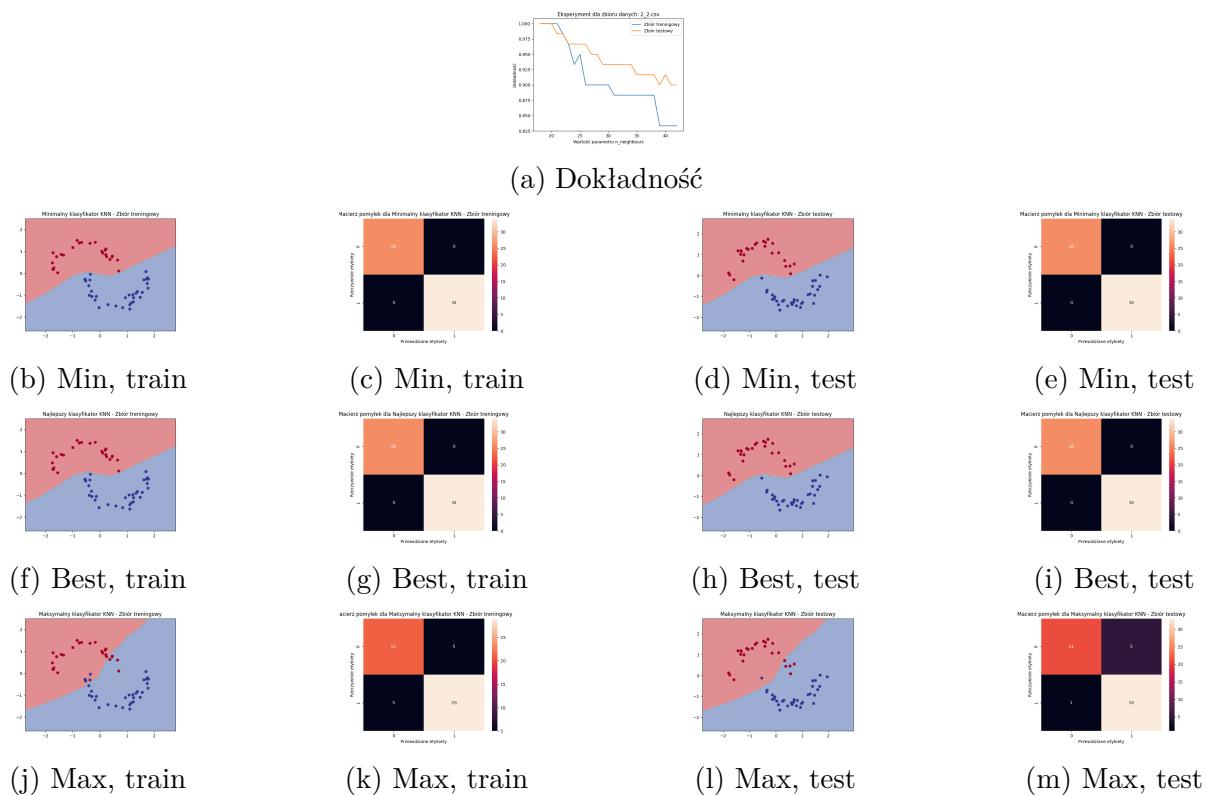
Rysunek 6: Eksperyment 2 — SVM na zbiorze 2\_3



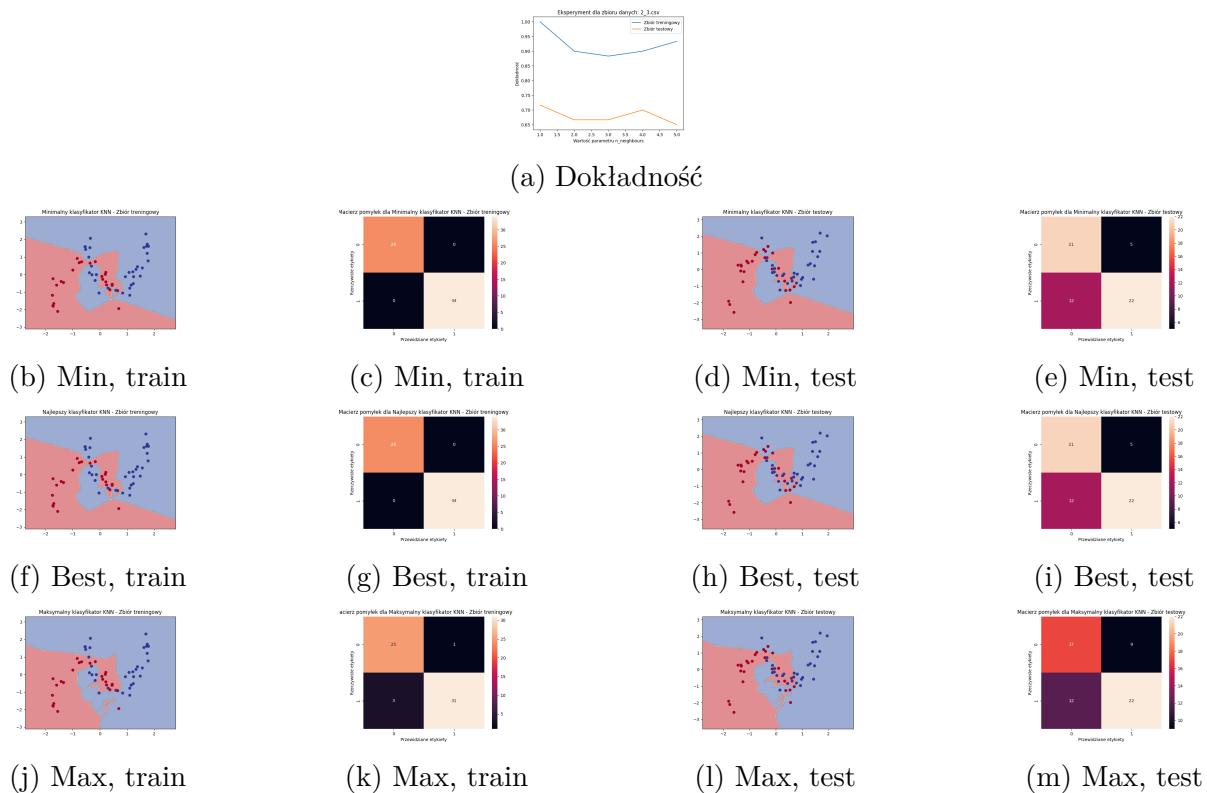
Rysunek 7: Eksperyment 2 — MLP na zbiorze 2\_2



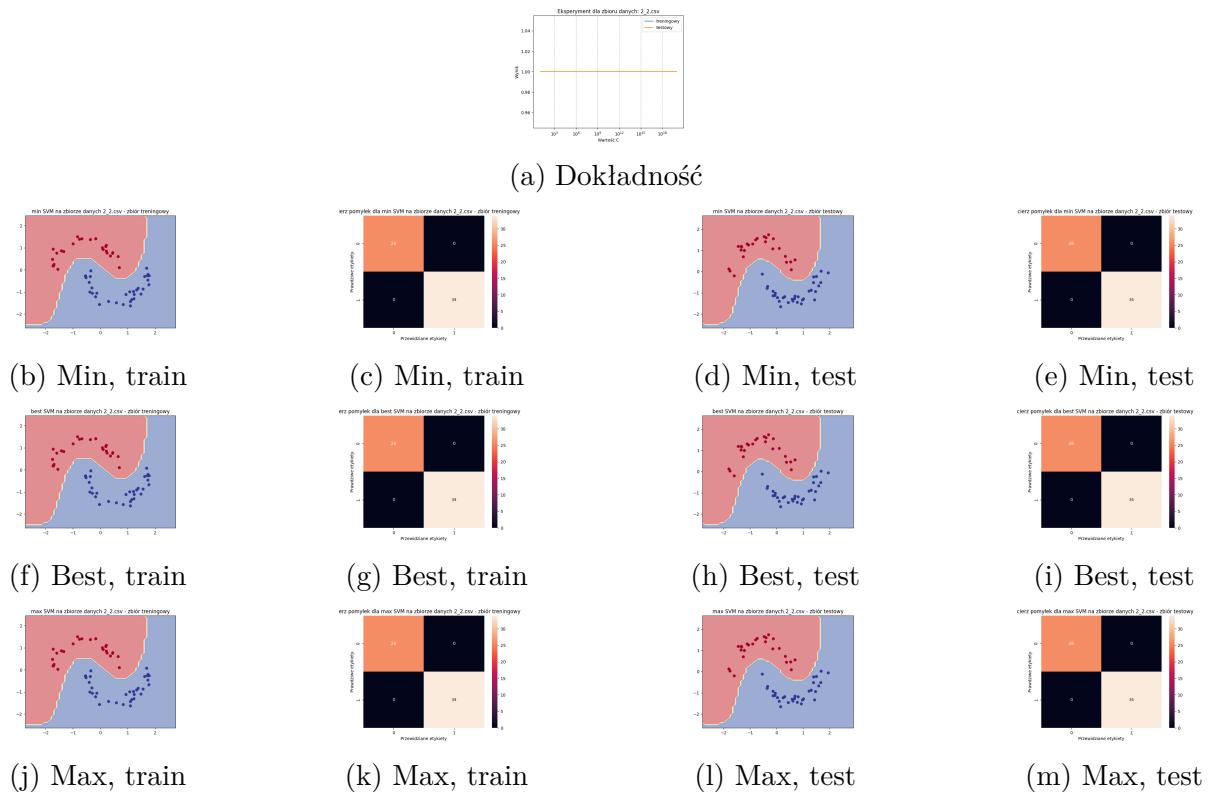
Rysunek 8: Eksperyment 2 — MLP na zbiorze 2\_3



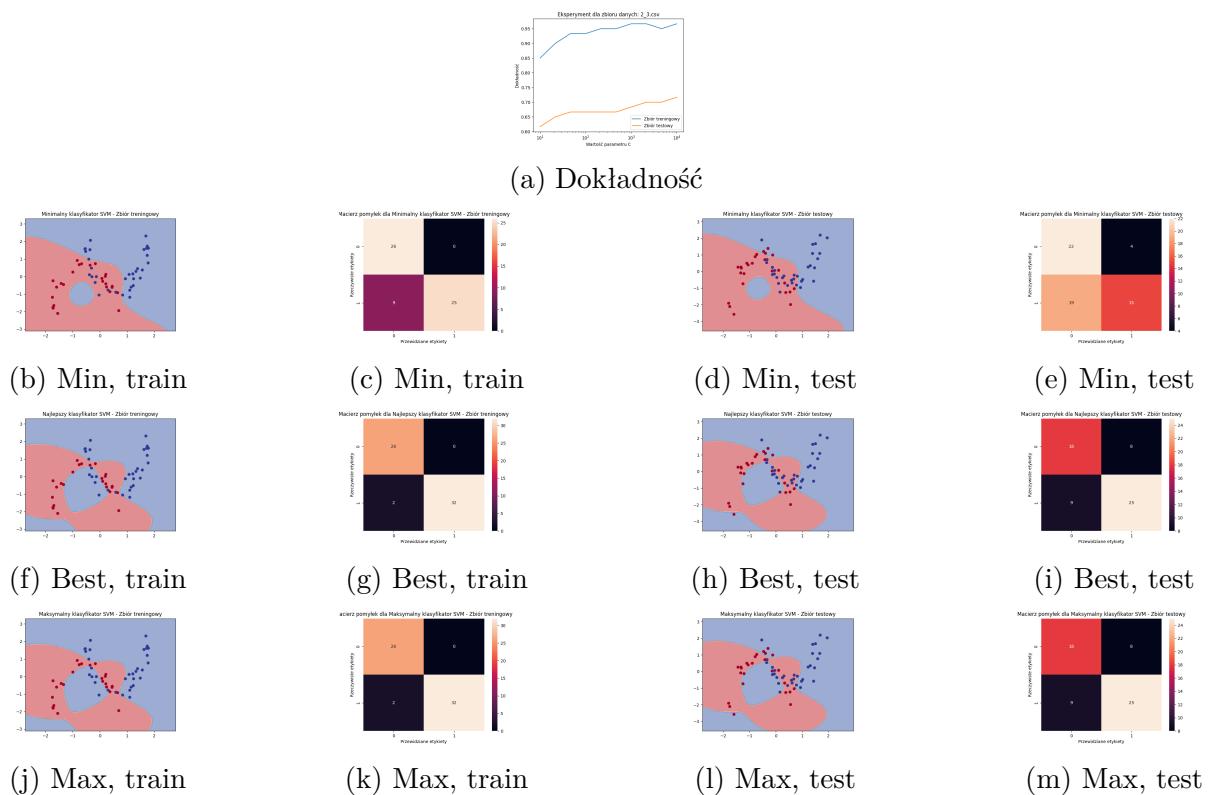
Rysunek 9: Eksperyment 3 — KNN na zbiorze 2\_2



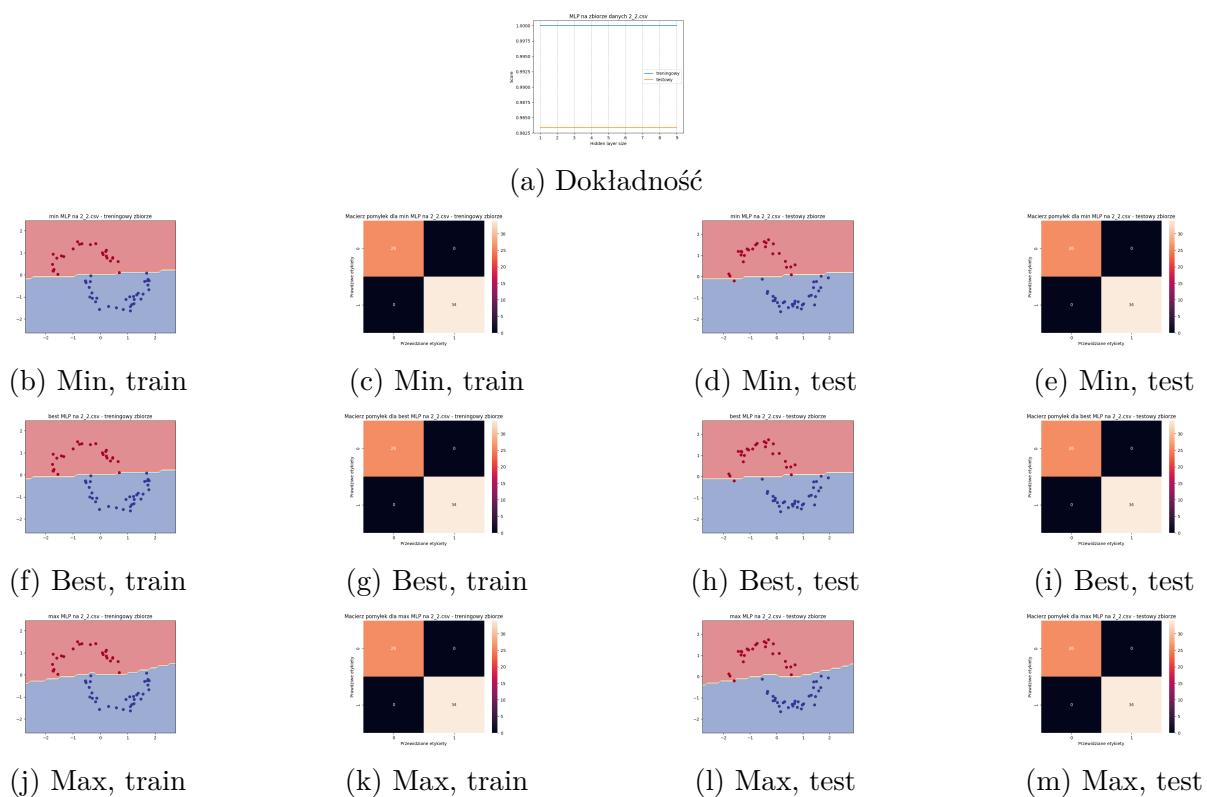
Rysunek 10: Eksperyment 3 — KNN na zbiorze 2\_3



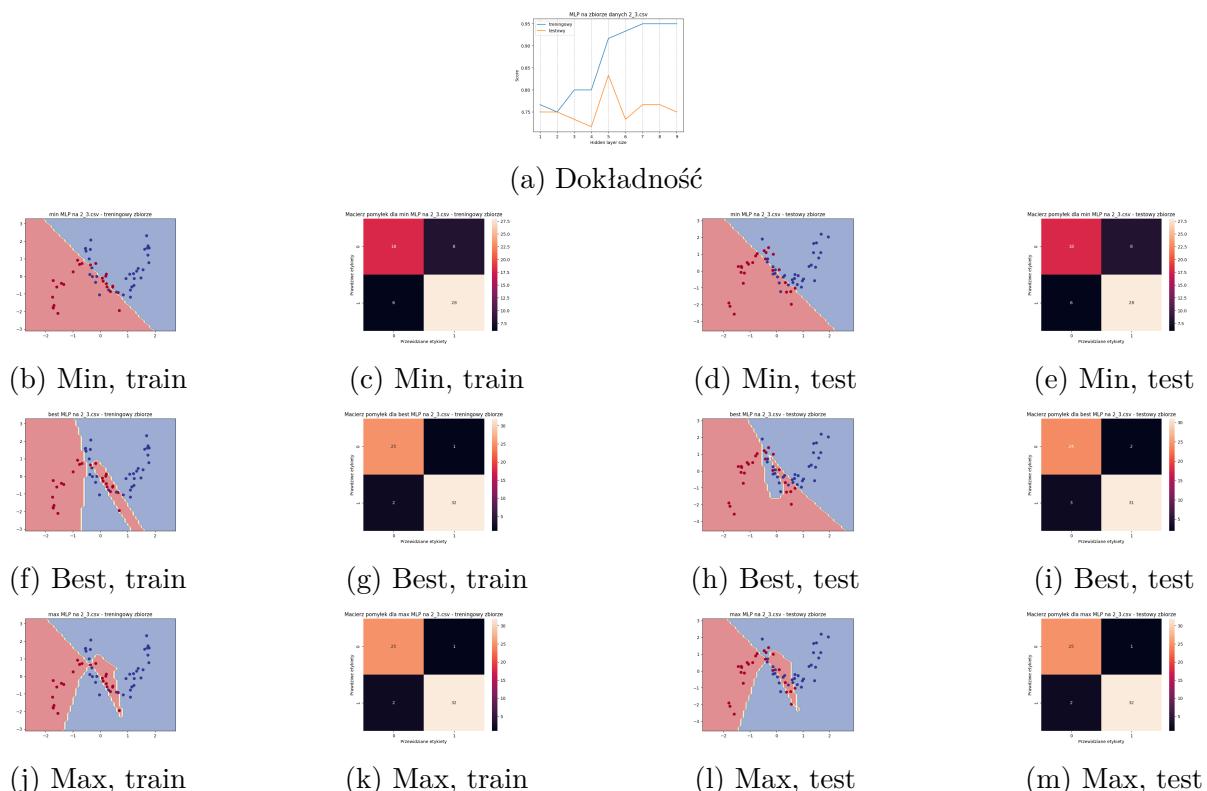
Rysunek 11: Eksperyment 3 — SVM na zbiorze 2\_2



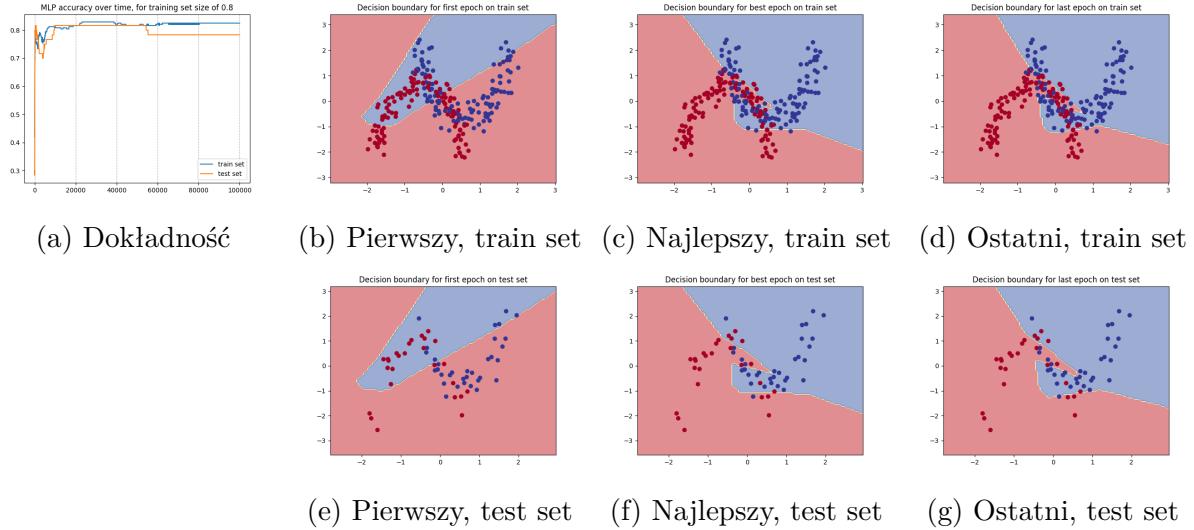
Rysunek 12: Eksperyment 3 — SVM na zbiorze 2\_3



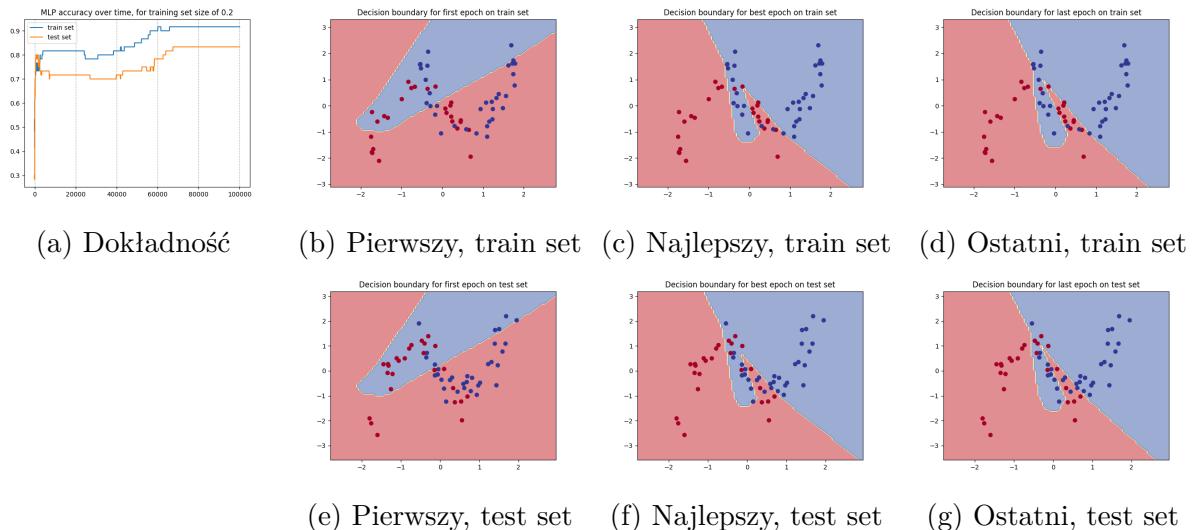
Rysunek 13: Eksperyment 3 — MLP na zbiorze 2\_2



Rysunek 14: Eksperyment 3 — MLP na zbiorze 2\_3



Rysunek 15: Trenowanie na 0.8 danych



Rysunek 16: Trenowanie na 0.2 danych

seed	pierwszy, train	najlepszy, train	najlepsza epoka	ostatni, train	pierwszy, test	najlepszy, test	najlepsza epoka	ostatni, test
12	0.587	0.895	38,320	0.891	0.633	0.800	44,930	0.800
31	0.516	0.820	32,325	0.812	0.433	0.733	722	0.716
16	0.516	0.841	44,575	0.829	0.433	0.783	11,244	0.750
2,353	0.545	0.795	77,067	0.795	0.766	0.850	74	0.783
314	0.308	0.791	24,176	0.783	0.400	0.783	60,806	0.783
6,523	0.541	0.779	25,312	0.775	0.416	0.766	404	0.716
634	0.620	0.837	9,400	0.825	0.450	0.733	329	0.700
23	0.491	0.783	275	0.779	0.566	0.766	38	0.700
802	0.516	0.920	75,135	0.920	0.433	0.800	39,816	0.800
134	0.379	0.808	94,967	0.808	0.333	0.733	1,268	0.700

Tablica 1: Trenowanie na 0.8 danych

seed	pierwszy, train	najlepszy, train	najlepsza epoka	ostatni, train	pierwszy, test	najlepszy, test	najlepsza epoka	ostatni, test
12	0.666	0.966	69,874	0.950	0.633	0.766	1,812	0.733
31	0.433	0.850	118	0.833	0.433	0.750	101	0.616
16	0.433	0.900	519	0.900	0.433	0.783	463	0.633
2,353	0.566	0.966	42,899	0.933	0.766	0.850	120	0.750
314	0.316	0.883	97,792	0.883	0.400	0.783	714	0.650
6,523	0.466	0.800	364	0.800	0.416	0.783	343	0.683
634	0.650	0.850	143	0.850	0.450	0.733	5,828	0.683
23	0.583	0.783	921	0.750	0.566	0.783	206	0.766
802	0.433	0.950	294	0.933	0.433	0.766	208	0.733
134	0.466	0.850	149	0.850	0.333	0.716	1,921	0.683

Tablica 2: Trenowanie na 0.2 danych

9 strona — Opis wniosków z eksperymentów przeprowadzonych na sztucznie wygenerowanych zbiorach. W przypadku wszystkich eksperymentów należy zwrócić uwagę na kształt uzyskiwanych granic decyzyjnych i związane z nim zdolności uogólniające poszczególnych rodzajów klasyfikatorów (wpływ hiperparametrów) oraz wpływ liczby danych treningowych. W eksperymencie czwartym należy dodatkowo skupić się na zdolnościach uogólniających w kolejnych epokach nauki oraz na wpływie sposobu zainicjalizowania sieci. Wnioski powinny mieć charakter ogólny, pozwalający przenieść je na przypadek, w którym nie ma możliwości zwizualizowania danych. Każdy wniosek powinien być poparty odniesieniami do wyników przedstawionych na pierwszych czterech stronach raportu.

## Eksperiment 1

Z eksperymentów na wygenerowanych danych można wyciągnąć wnioski dotyczące elastyczności rozważanych klasyfikatorów oraz wpływu ich hiperparametrów na kształt granic decyzyjnych. W przypadku klasyfikatora SVM istotnym parametrem jest kernel, który definiuje kształt granicy decyzyjnej. Porównując różne kernele, takie jak linear i rbf, można zauważać różnice w elastyczności modelu. Podobnie, dla klasyfikatora opartego o sieć MLP, parametr activation wpływa na kształt granicy decyzyjnej, dlatego porównanie różnych funkcji aktywacji, takich jak identity i relu, jest istotne dla oceny elastyczności modelu.

## Eksperiment 2

Drugi eksperiment koncentruje się na wpływie elastyczności modelu na jego zdolności generalizacyjne. Zmiana hiperparametrów, takich jak liczba sąsiadów dla klasyfikatora K-NN, parametr C dla klasyfikatora SVM oraz liczba neuronów w warstwie ukrytej dla sieci MLP, ma istotny wpływ na zdolności generalizacyjne modelu. Badanie tego wpływu na podziale danych na zbiór treningowy i testowy pozwala ocenić skuteczność klasyfikacji na nowych, nie widzianych wcześniej danych, co można zaobserować na przeprowadzonych testach.

## Eksperiment 3

Trzeci eksperiment rozważa wpływ zmiany hiperparametrów modelu na jego zdolności generalizacyjne w przypadku niewielkiej liczby danych treningowych równej 0.2. Przy ograniczonym zbiorze treningowym istotne staje się dobranie optymalnych hiperparametrów, aby uniknąć przeuczenia, co można zaobserwować na zmianie wykresu accuracy, gdzie w przypadku zbioru 2\_2 przez pierwsze 30 ukrytych warstw nie ma zmiany, a w przypadku 2\_3 ma to ogromne znaczenie, dlatego przedstawiono tylko pierwsze warstwy. Wynika to ze specyfikacji danego zbioru. Porównanie różnych kombinacji hiperparametrów pozwala zidentyfikować te, które prowadzą do najlepszych wyników przy ograniczonej liczbie danych.

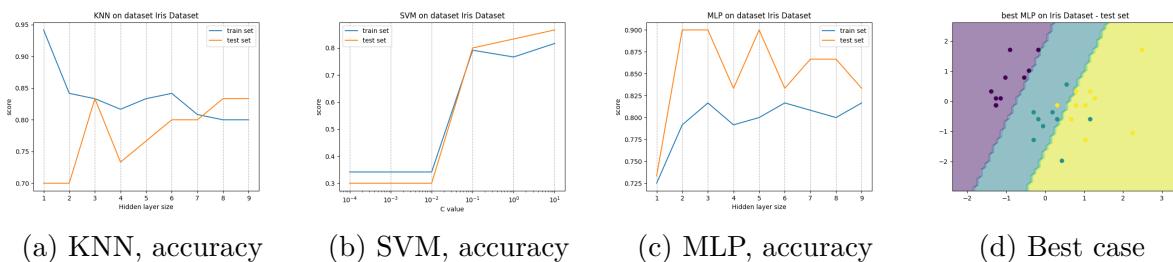
## Eksperiment 4

Czwarty eksperiment skupia się na obserwacji procesu nauki sieci MLP. Dzięki wykorzystaniu metody `partial_fit` można śledzić zmiany skuteczności modelu na zbiorze treningowym i testowym po kolejnych epokach nauki. Dodatkowo, badając wpływ różnych inicjalizacji wag neuronów na finalne rezultaty klasyfikacji, można lepiej zrozumieć proces uczenia się sieci i jego wpływ na zdolności generalizacyjne modelu.

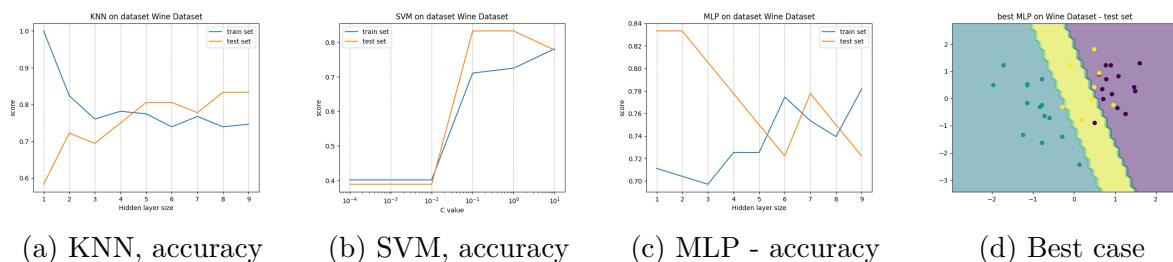
10 strona — Opis działania analizowanych metod klasyfikacji w przypadku rzeczywistych zbiorów danych. Podczas tworzenia klasyfikatorów warto skorzystać z wniosków wyciągniętych podczas wcześniejszych eksperymentów. Uzyskane wyniki należy zaprezentować w zwartej formie (warto wykorzystać tabele i/lub wykresy), a wnioski należy poprzedzić odwołaniami do tych wyników.

Rysunki 15 - 17 przedstawiają wyniki eksperymentów z użyciem KNN, SVM i MLP na zbiorach Iris, Wine oraz Breast Cancer Wisconsin W przypadku metody K-NN skoncentrowaliśmy się na optymalnej liczbie sąsiadów  $n_{neighbours}$ . Dla metody SVM dobraliśmy optymalną wartość parametru C, kontrolującego tolerancję naruszenia marginesu. Natomiast dla sieci MLP ustaliliśmy optymalną liczbę neuronów w warstwie ukrytej.

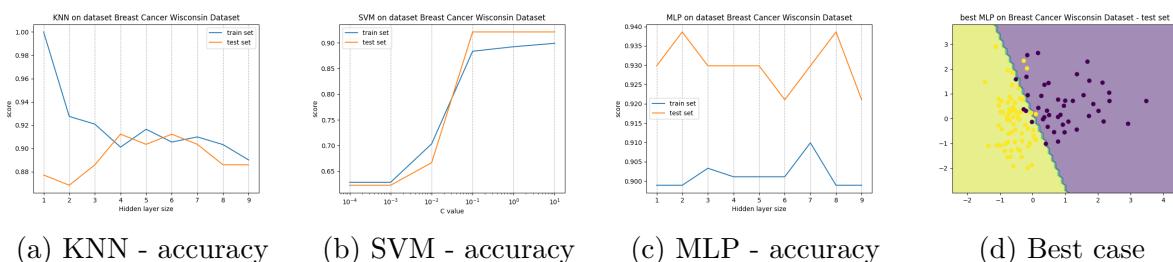
Wyniki działania klasyfikatorów na rzeczywistych danych zostały przedstawione w formie tabel oraz wykresów. Dokładnie przeanalizowaliśmy skuteczność klasyfikacji na zbiorze treningowym i testowym, a także zbadaliśmy macierz pomyłek dla każdej z metod. Nasza analiza wskazuje, że wybrane metody klasyfikacji dobrze radzą sobie z rzeczywistymi danymi. Klasyfikatory osiągają zadowalające wyniki zarówno na zbiorach treningowych, jak i testowych



Rysunek 17: Wyniki eksperymentów na zbiorze Iris



Rysunek 18: Wyniki eksperymentów na zbiorze Wine



Rysunek 19: Wyniki eksperymentów na zbiorze Breast Cancer Wisconsin