


1 Eksperyment 1: Architektury sieci spłotowej dla MNIST (JakubPawlak)

Pierwsza architektura


Pierwsza architektura składa się z warstwy spłotowej z jądrem 5×5 , na wyjściu której obraz ma 6 kanałów, następnie jest przepuszczony przez funkcję sigmoid oraz max pooling. Zamierzeniem jest, aby ta warstwa wykrywała krawędzie lub rogi cyfr. Z tego też powodu, użyto funkcji aktywacji sigmoid, ponieważ funkcja ReLU całkowicie zeruje ujemne wartości. W przypadku wykrywania krawędzi, ujemne wartości mogą być używane do reprezentacji kierunku.

Drugi spłot prowadzi do 16 kanałów i ponownie jest używana funkcja sigmoid oraz max pooling. Zadaniem tej warstwy jest rozpoznanie większych, bardziej złożonych kształtów. Finalnie ekstraktor prowadzi do tensora $16 \times 5 \times 5$, który zostaje spłaszczony.

Klasyfikator to MLP z rozmiarami warstw odpowiednio 400, 120, 84, 10, używający sigmoidy jako funkcji aktywacji.




(a) Wykres zmian accuracy




(b) Macierz pomyłek

Rysunek 1: Wyniki dla 1 architektury (Train acc: 0.997; Test acc: 0.987)

Druga architektura, prowadząca do ekstrakcji 2 cech



(a) Wykres zmian accuracy



(b) Macierz pomyłek

Rysunek 2: Wyniki dla 2 architektury (Train acc: 0.836; Test acc: 0.866)

W drugiej architekturze warunkiem koniecznym jest rozmiar wektora cech, wynoszący 2 cechy. Jest to umotywowane chęcią stworzenia wizualizacji granic decyzyjnych. Ekstraktor cech składa się z następujących warstw:


```
(feature_extractor): Sequential(
  (0): Conv2d(1, 10, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
  (1): ReLU()
  (2): Dropout2d(p=0.1, inplace=False)
  (3): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (4): Conv2d(10, 5, kernel_size=(5, 5), stride=(1, 1))
  (5): ReLU()
  (6): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (7): Conv2d(5, 2, kernel_size=(3, 3), stride=(1, 1))
  (8): ReLU()
  (9): Flatten(start_dim=1, end_dim=-1)
  (10): Linear(in_features=18, out_features=2, bias=True)
)
(classifier): Sequential(
  (0): Linear(in_features=2, out_features=5, bias=True)
  (1): ReLU()
  (2): Linear(in_features=5, out_features=10, bias=True)
)
```

W tym modelu, aby jeszcze bardziej zmniejszyć ilość cech, zastosowano jeszcze jedną warstwę konwolucyjną. Finalnie, ekstraktor cech zawiera jedną w pełni połączoną warstwę, w celu redukcji do 2 cech.

W tym modelu postanowiono również przeprowadzić eksperyment z użyciem warstwy dropout w celu poprawienia odporności na overfitting. Pomimo, że z racji na dużą licznosc zbioru treningowego, w eksperymencie 1 nie ma dużego ryzyka przetrenowania, sytuacja może ulec zmianie w eksperymencie 2. Negatywnym efektem użycia warstwy dropout jest spowolnienie procesu uczenia, co jest dobrze widoczne na wykresie.

Warstwy konwolucyjne prowadzą do finalnego tensora o wymiarach $2 \times 3 \times 3$, 10więc na końcu ekstraktora cech znajduje się jeszcze jedna warstwa linear, tworząca 2-wymiarowy wektor cech.

Klasyfikator zawiera jedną warstwę ukrytą o rozmiarze 5 neuronów, z funkcją relu, a następnie warstwę wyjściową o rozmiarze 10 neuronów.




Rysunek 3: Granica decyzyjna dla arch. 2

2 Eksperyment 1: Architektury sieci spłotowej dla MNIST (Magdalena Pakuła)

Pierwsza architektura

Zawiera trzy warstwy spłotowe każda warstwa wydobywa coraz bardziej abstrakcyjne cechy. Warstwy początkowe rejestrują krawędzie i tekstury, podczas gdy warstwy głębsze rejestrują kształty i bardziej złożone wzory. Ma to kluczowe znaczenie w przypadku rozpoznawania cyfr, gdzie należy rozróżnić subtelne różnice. Po każdej warstwie spłotowej następuje redukcja wymiarowości, dzięki użyciu MaxPool2d, co pozwala sieci skupić się na najbardziej istotnych cechach cyfr, poprawiając generalizację. Stopniowy wzrost filtrów (8, 16, 32) zapewnia równowagę między wydajnością obliczeniową a bogactwem funkcji. Ostatecznie model zostaje spłaszczony do 288 obiektów, co jest wystarczającą pojemnością do reprezentowania złożonych wzorów, nie będąc jednocześnie zbyt dużym, co mogłoby prowadzić do nadmiernego dopasowania.

Rezultaty tej metody zostały przedstawione poniżej na wykresie accuracy, macierzy pomyłek i wyników accuracy dla najlepszego modelu na rys. 4.




Rysunek 4: Wyniki dla 1 architektury (Train acc: 0.988; Test acc: 0.984)

Druga architektura, prowadząca do ekstrakcji 2 cech

Składa się z czterech warstw spłotowych. Liczba filtrów w tych warstwach jest hierarchicznie zwiększana (32,64,128) kończąc na 2. Po każdej warstwie spłotowej następuje normalizacja wsadowa (BatchNorm2d), funkcja aktywacji ReLU i redukcja wymiarowości poprzez użycie operacji MaxPool2d, z wyjątkiem ostatniej warstwy, gdzie ta operacja nie jest już potrzebna. Taka konfiguracja została zaprojektowana w celu stopniowego wyodrębniania coraz bardziej skomplikowanych cech z obrazów MNIST. Pierwsze warstwy koncentrują się na wykrywaniu podstawowych cech, takich jak krawędzie i rogi, dzięki mniejszej liczbie filtrów. Następnie, w kolejnych warstwach, liczba filtrów jest stopniowo zwiększana. Operacje normalizacji wsadowej pomagają w stabilizacji uczenia poprzez zapewnienie jednolitego zakresu wartości na wyjściu z każdej warstwy, co może przyspieszyć proces uczenia oraz poprawić ogólną wydajność sieci. Funkcja aktywacji ReLU została wybrana z powodu jej skuteczności w eliminowaniu zjawiska zanikającego gradientu i aktywowania jedynie istotnych cech.

Rezultaty tej metody zostały przedstawione poniżej na rys. 5.



Rysunek 5: Wyniki dla 2 architektury (Train acc: 0.871; Test acc: 0.869)

Ekstraktor cech składa się z następujących warstw:


```
(feature_extractor): Sequential(
  (0): Conv2d(1, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (1): BatchNorm2d(32)
  (2): ReLU()
  (3): MaxPool2d(kernel_size=2, stride=2) # 32x28x28 -> 32x14x14

  (4): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (5): BatchNorm2d(64)
  (6): ReLU()
  (7): MaxPool2d(kernel_size=2, stride=2)

  (8): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (9): BatchNorm2d(128)
  (10): ReLU()
  (11): MaxPool2d(kernel_size=2, stride=2)

  (12): Conv2d(128, 2, kernel_size=(3, 3))
  (13): BatchNorm2d(2)
  (14): ReLU()
  (15): Flatten(start_dim=1)
)

(classifier): Sequential(
  (0): Linear(in_features=2, out_features=5, bias=True)
  (1): ReLU()
  (2): Linear(in_features=5, out_features=10, bias=True)
)
```



Rysunek 6: Granica decyzyjna dla arch. 2

3 Eksperyment 1: Architektury sieci spłotowej dla CIFAR10 (Jakub Pawlak)

Pierwsza architektura

Obrazy w zbiorze CIFAR10 są dużo bardziej złożone niż cyfry ze zbioru MNIST. Przede wszystkim zawierają 3 kanały, a dodatkowo przedstawiają obiekty bardziej skomplikowane niż kształty cyfr.

Taka charakterystyka zbioru warunkuje zastosowanie głębszych sieci, zdolnych do ekstrakcji bardziej złożonych cech.


Głębsze architektury sieci skutkują większą ilością parametrów, a co za tym idzie, wolniejszym procesem uczenia. W celu przyspieszenia uczenia, zdecydowano się na normalizację danych za pomocą warstw BatchNorm2d.

Ponadto, postanowiono poczynić eksperyment z połączeniami resztkowymi, inspirowanymi sieciami ResNet.


Ekstraktor cech składa się z 3 głównych etapów: **step_1**, **step_2**, **step_3**. Zawierają one warstwy spłotowe, normalizacyjne, nieliniowe funkcje aktywacji, jak również max pooling. Zadaniem tych etapów jest zmniejszenie rozmiarów obrazu jak i ilości kanałów (za wyjątkiem etapu **step_1**, który zwiększa ilość kanałów, w celu ekstrakcji jak największej ilości cech w początkowej fazie).

Dodatkowo, etapy główne są oddzielone dwoma modułami resztkowymi (**residual_1** oraz **residual_2**), które nie zmieniają wymiarów obrazu. Wejście do kolejnych warstw głównych stanowi suma wyjść z poprzedniej warstwy resztkowej oraz głównej.

Dzięki temu sieć staje się bardziej elastyczna — jeśli warstwy spłotowe nie są konieczne, sieć może wyuczyć się w ten sposób, aby wyjście z warstwy resztkowej było równe 0. W ten sposób do następnego modułu głównego zostanie przekazane po prostu wyjście z poprzedniego modułu głównego, efektywnie “pomijając” moduł resztkowy.




(a) Wykres zmian accuracy




(b) Macierz pomyłek

Rysunek 7: Wyniki dla 1 architektury (Train acc: 0.931; Test acc: 0.810)

Druga architektura prowadząca do ekstrakcji 2 cech



(a) Wykres zmian accuracy




(b) Macierz pomyłek

Rysunek 8: Wyniki dla 2 architektury (Train acc: 0.607; Test acc: 0.547)

Druga architektura, podobnie jak przy zbiorze MNIST, dokonuje ekstrakcji cech do 2-elementowego wektora. Z uwagi na niską rozdzielczość obrazków zdecydowano się użyć niewielkiego rozmiaru jądra w warstwach spłotowych. Podobnie jak w poprzednim modelu, dla przyspieszenia uczenia użyto warstw BatchNorm2d. Standardowo, w celu zmniejszenia rozmiaru obrazów, a co za tym idzie ilości parametrów, użyte są warswty max pooling. Na końcu ekstraktora cech dane zostają spłaszczone do 2-elementowego wektora.

Klasyfikator standardowo składa się z 2 w pełni połączonych warstw.

```
(feature_extractor): Sequential(
  (0): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
  (2): ReLU()
  (3): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (4): Conv2d(64, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (5): BatchNorm2d(32, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
  (6): ReLU()
  (7): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (8): Conv2d(32, 8, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (9): ReLU()
  (10): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (11): Conv2d(8, 2, kernel_size=(4, 4), stride=(1, 1))
  (12): Flatten(start_dim=1, end_dim=-1)
)
(classifier): Sequential(
  (0): Linear(in_features=2, out_features=16, bias=True)
  (1): ReLU()
  (2): Linear(in_features=16, out_features=10, bias=True)
)
```




Rysunek 9: Granica decyzyjna dla arch. 2


4 Eksperyment 1: Architektury sieci spłotowej dla CIFAR10 (Magdalena Pakuła)

Pierwsza architektura

Sklada się z trzech warstw spłotowych, gdzie każda z nich wykorzystuje coraz większą liczbę filtrów o rozmiarze 3x3. Pierwsza warstwa spłotowa zawiera 32 filtry, stosuje funkcję aktywacji ReLU oraz warstwę Dropout z współczynnikiem 0.2, która losowo wyłącza część neuronów, zapobiegając nadmiernemu dopasowaniu. Następnie warstwa MaxPooling zmniejsza rozmiar przestrzenny danych o połowę. Druga warstwa spłotowa składa się z 64 filtrów, ponownie stosuje ReLU oraz Dropout z współczynnikiem 0.3, a także warstwę MaxPooling, która zmniejsza rozmiar przestrzenny danych do 8x8. Trzecia warstwa spłotowa zawiera 128 filtrów, stosuje ReLU, Dropout z współczynnikiem 0.4 oraz MaxPooling, zmniejszając rozmiar przestrzenny danych do 4x4. Dane są następnie spłaszczone do jednowymiarowego tensora za pomocą warstwy Flatten, umożliwiając przekazanie ich do warstw w pełni połączonych w celu klasyfikacji. Klasyfikator składa się z dwóch warstw w pełni połączonych, gdzie pierwsza redukuje rozmiar cech do 128, stosując funkcję ReLU oraz Dropout z współczynnikiem 0.5, a druga warstwa klasyfikuje dane do liczby klas. Ta architektura została zoptymalizowana w celu efektywnego wyodrębniania cech z obrazów o niskiej rozdzielczości, takich jak te występujące w zbiorze CIFAR. Większa liczba warstw spłotowych oraz zwiększenie liczby filtrów w każdej warstwie pozwalają na lepsze modelowanie danych, jednak możemy też zauważyć dosyć niskie train accuracy ze względu na ilość użyć funkcji Dropout. Rezultaty tej metody zostały przedstawione na rys. 10.




(a) Wykres zmian accuracy




(b) Macierz pomyłek

Rysunek 10: Wyniki dla 1 architektury (Train acc: 0.623; Test acc: 0.679)

Druga architektura prowadząca do ekstrakcji 2 cech



(a) Wykres zmian accuracy



(b) Macierz pomyłek

Rysunek 11: Wyniki dla 2 architektury (Train acc: 0.539; Test acc: 0.573)

Sklada się z 4 warstw spłotowych z 32, 64 i 128 filtrami, które pozwalają na stopniowe wyodrębnianie coraz bardziej złożonych cech z danych wejściowych. Następnie użycie BatchNorm2d stabilizuje proces treningu i pozwala na szybsze uczenie się modelu, a funkcja aktywacji ReLU wprowadza nieliniowość. Następnie jest warstwa MaxPooling redukująca rozmiar danych. Ostatnia warstwa spłotowa prowadzi do 2 filtrów. Na końcu dodana jest funkcja aktywacji ReLU. Klasyfikator składa się z trzech warstw w pełni połączonych, które stopniowo redukują rozmiar cech i umożliwiają klasyfikację danych do odpowiedniej liczby klas. Dropout (0.3) w pierwszej warstwie w pełni połączonej zapobiega nadmiernemu dopasowaniu modelu poprzez losowe wyłączenie neuronów podczas treningu. Możemy dostrzec różnicę w klasyfikacji modelu, a użyciem funkcji Dropout w obu architekturach.


Rezultaty przedstawione są na rys. 11.

```
(feature_extractor): Sequential(
  (0): Conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (1): BatchNorm2d(32)
  (2): ReLU()
  (3): MaxPool2d(kernel_size=2, stride=2)

  (4): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (5): BatchNorm2d(64)
  (6): ReLU()
  (7): MaxPool2d(kernel_size=2, stride=2)

  (8): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
  (9): BatchNorm2d(128)
  (10): ReLU()
  (11): MaxPool2d(kernel_size=2, stride=2)

  (12): Conv2d(128, 2, kernel_size=(4, 4))
  (13): ReLU()
  (14): Flatten(start_dim=1)
)
(classifier): Sequential(
  (0): Linear(in_features=2, out_features=128, bias=True)
  (1): ReLU()
  (2): Dropout(p=0.3)
  (3): Linear(in_features=128, out_features=64, bias=True)
  (4): ReLU()
  (5): Linear(in_features=64, out_features=num_classes, bias=True)
)
```




Rysunek 12: Granica decyzyjna dla arch. 2

5 Eksperyment 2: Wyniki dla MNIST

Augmentacje

Augmentacje:

1. `v2.RandomAffine(degrees=10, scale=(0.6, 1.5), shear=20)` — Jakub Pawlak
2. `v2.ElasticTransform(alpha=50.0, sigma=5.0)` — Magdalena Pakuła - Technika ta symuluje lekkie wypaczenie lub rozciągnięcie odręcznie zapisanych cyfr, naśladując naturalne różnice w sposobie pisania. Ma to znaczenie dla zbioru MNIST, ponieważ pismo odręczne w świecie rzeczywistym może być nieco zniekształcone w porównaniu z cyfrą idealnie wyśrodkowaną i proporcjonalną.



(a) Jakub Pawlak



(b) Magdalena Pakuła

Rysunek 13: Augmentacje dla zbioru MNIST (górny wiersz zawiera oryginalne obrazki)

Najlepsza architektura

Architektura Kuba

Augmentacja	Ilość obrazów		
	10	200	1000
Jakub Pawlak	0.100 ± 0.001	0.795 ± 0.042	0.921 ± 0.024

Tablica 1: Wyniki dla 1 architektury na zbiorze MNIST z augmentacją (accuracy z 10 prób w formie $\mu \pm \sigma$)

Najlepsza architektura prowadząca do ekstrakcji 2 cech

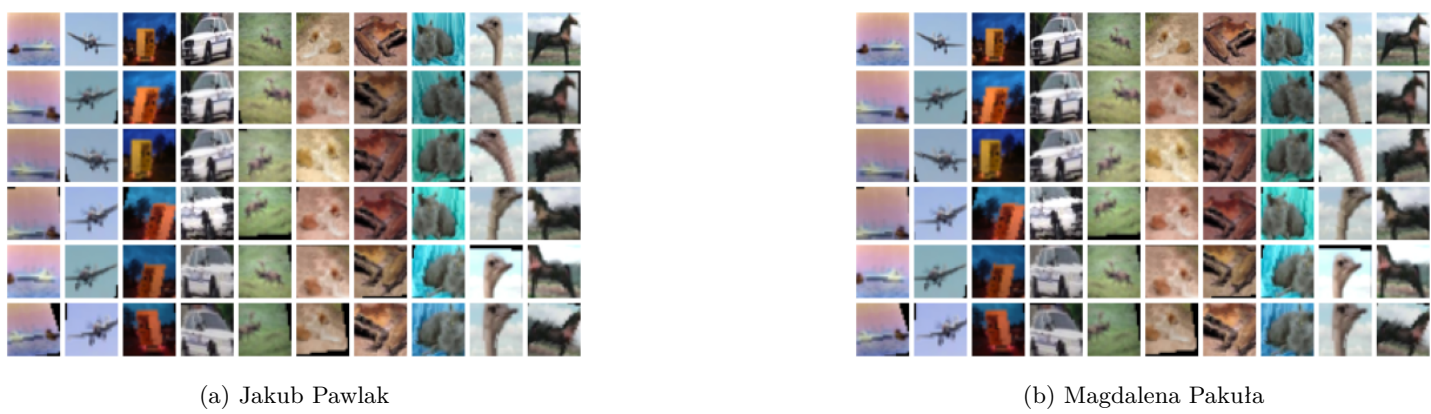
Architektura Magda

Augmentacja	Ilość obrazów		
	10	200	1000
Jakub Pawlak	0.106 ± 0.031	0.385 ± 0.037	0.530 ± 0.045
Magdalena Pakuła	0.134 ± 0.041	0.375 ± 0.054	0.533 ± 0.039

Tablica 2: Wyniki dla 2 architektury na zbiorze MNIST z augmentacją (accuracy z 10 prób w formie $\mu \pm \sigma$)

6 Eksperyment 2: Wyniki dla CIFAR10

Augmentacje



Rysunek 14: Augmentacje dla zbioru CIFAR10 (górny wiersz zawiera oryginalne obrazki)

Najlepsza architektura

Arch. Kuba

Augmentacja	Ilość obrazów		
	10	200	1000
Jakub Pawlak	0.126 ± 0.014	0.298 ± 0.021	0.466 ± 0.029

Tablica 3: Wyniki dla 1 architektury na zbiorze MNIST z augmentacją (accuracy z 10 prób w formie $\mu \pm \sigma$)

Najlepsza architektura prowadząca do ekstrakcji 2 cech

Arch. Magda

Augmentacja	Ilość obrazów		
	10	200	1000
Jakub Pawlak	0.100 ± 0.001	0.100 ± 0.000	0.137 ± 0.046

Tablica 4: Wyniki dla 2 architektury na zbiorze MNIST z augmentacją (accuracy z 10 prób w formie $\mu \pm \sigma$)

7 Analiza i wnioski

Porównanie architektur sieci splotowych

Generalne wnioski Magdy dla MNIST: wyszło zajebiscie, rezultaty same pokazują — można się bić :) Generalne wnioski Magdy dla CIFAR: nie wyszło zajebiscie, wyniki są słabe. Dla 1 archi nie udało mi się stworzyć modelu który by nie robił underfittug — wszystkie mniej czy więcej to robiły, a dla zachowania podobnych experymentow co Kuba to nie zmieniałam learning rate. Zmieniałam relu, conv layers, filters ale obecny model to mój najlepszy. Jeśli chodzi o Archi 2 to też mój najlepszy model który stworzyłam, mamy znowu lekki underfitting wiadomka że dla 2 cech beda to znacznie gorsze wyniki w szczegolnosc i nieczytelnych obrazkow jak CIFAR. – Model Kuby dla Cifara jest better bo...— tutaj wyjaśnienie czemu jest taki boski.

Wpływ augmentacji danych